Qwen3.6-35B-A3B，BitNet加速比测试

> 核心问题：
>
> 把 Qwen3.6-35B-A3B 的哪些部分量化，能省多少内存、损失多少效果、在 CPU 上能否真正加速？

1. 实验表格

Setting	Shared expert 投影	Full-attention 投影	GDN 投影	
S1：官方原始 BF16 baseline	BF16	BF16	BF16	69
S2：当前位置，BF16 scales	BF16	BF16	BF16	12
S3：S2 + shared	w1.58	BF16	BF16	12
S4：S2 + full-attention	BF16	w1.58	BF16	11
S5：S2 + GDN	BF16	BF16	w1.58	10
S6：S2 + full-attention + GDN	BF16	w1.58	w1.58	10
S7：S6 + shared	w1.58	w1.58	w1.58	10
S8：S2 其余大 Linear 变 FP8 block	FP8-B128	FP8-B128	FP8-B128	11
S9：S2 其余大 Linear 变 INT8 block	INT8-B128	INT8-B128	INT8-B128	11

方案	要做的事情	
S1	官方原始 BF16，不量化，作为基准	
S2	路由专家三值量化，Embedding 和输出头 INT8；其余主投影保持 BF16	
S3	S2 基础上，再把共享专家投影三值化	
S4	S2 基础上，再把完整注意力投影三值化	
S5	S2 基础上，再把 GDN 投影三值化	
S6	S2 基础上，完整注意力和 GDN 投影都三值化	
S7	S6 基础上，再把共享专家投影三值化	
S8	从 S2 出发，把其余大投影改成 FP8	
S9	从 S2 出发，把其余大投影改成 INT8	

2. 在llama.cpp upstream master分支跑Qwen3-30B-A3B看吞吐是多少，自己的BitNet适配是否已经达到SOTA，还有无优化空间。

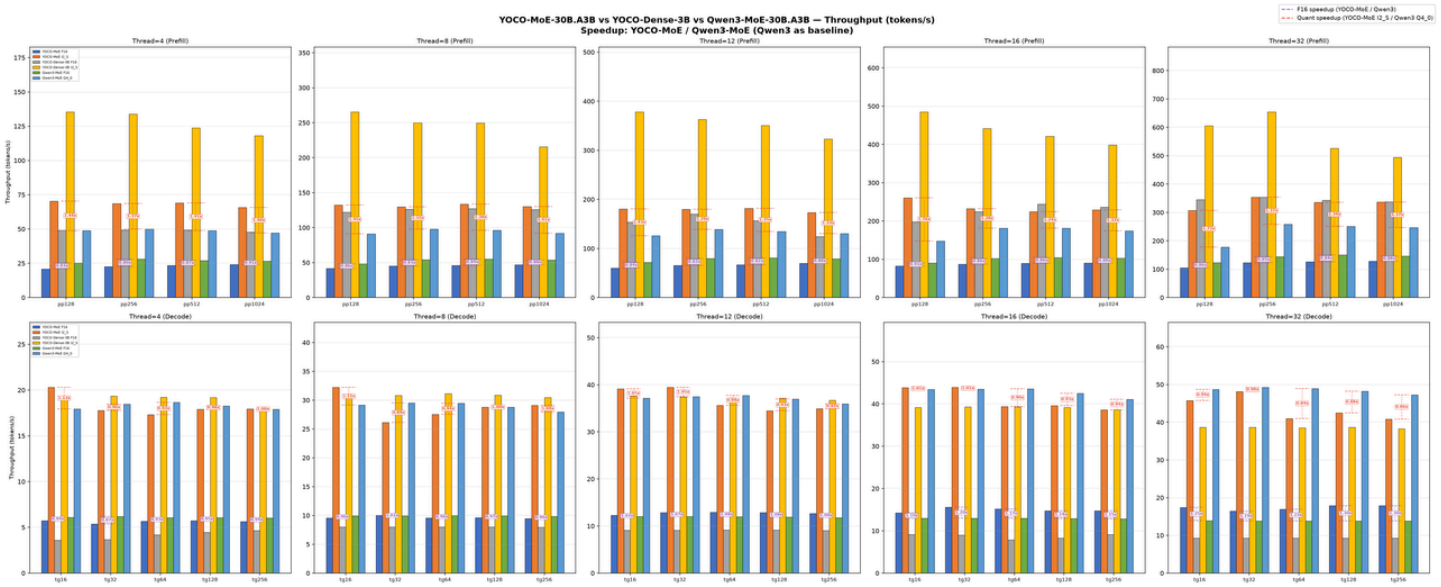
- Qwen3-MoE-30B-A3B，Q4_0
- 不开启TL2
  - F16.GGUF

Model | Thread Number Qwen3-MoE-30B.A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	25.28 ± 0.46	48.41 ± 0.73	71.78 ± 1.10	90.80 ± 2.63	122.83 ± 1.39
pp256	-	-	28.09 ± 0.74	54.41 ± 0.60	79.68 ± 0.61	102.09 ± 0.50	144.65 ± 0.24
pp512	-	-	26.99 ± 0.44	55.11 ± 0.63	81.14 ± 0.99	104.52 ± 0.37	150.41 ± 0.85
pp1024	-	-	26.47 ± 0.44	53.66 ± 0.81	79.12 ± 0.38	102.67 ± 0.15	145.93 ± 2.20
tg16	-	-	6.10 ± 0.07	9.94 ± 0.09	12.03 ± 0.01	12.95 ± 0.05	13.95 ± 0.02
pp32	-	-	6.19 ± 0.02	9.96 ± 0.01	12.03 ± 0.04	12.98 ± 0.01	13.81 ± 0.05
tg64	-	-	6.06 ± 0.01	9.97 ± 0.0	12.00 ± 0.01	12.98 ± 0.0	13.86 ± 0.11
tg128	-	-	6.07 ± 0.01	9.95 ± 0.01	11.93 ± 0.01	12.93 ± 0.01	13.80 ± 0.12
tg256	-	-	6.02 ± 0.01	9.83 ± 0.03	11.81 ± 0.00	12.84 ± 0.01	13.83 ± 0.09

  - Q4_0.GGUF

Model | Thread Number Qwen3-MoE-30B.A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-					

			49.00 ± 0.23	90.98 ± 8.36	125.99 ± 12.78	148.00 ± 3.51	178.48 ± 1.98
pp256	-	-	49.96 ± 0.28	97.91 ± 1.68	139.25 ± 0.46	181.48 ± 1.13	258.09 ± 12.81
pp512	-	-	49.01 ± 0.53	96.48 ± 1.31	134.91 ± 0.72	181.24 ± 0.80	251.21 ± 4.76
pp1024	-	-	47.05 ± 0.30	92.12 ± 0.11	130.17 ± 1.21	174.25 ± 0.20	246.48 ± 1.73
tg16	-	-	17.94 ± 0.50	29.14 ± 0.54	37.17 ± 0.07	43.43 ± 0.27	48.72 ± 1.08
pp32	-	-	18.45 ± 0.40	29.51 ± 0.44	37.46 ± 0.31	43.49 ± 0.49	49.23 ± 0.45
tg64	-	-	18.65 ± 0.05	29.47 ± 0.25	37.77 ± 0.18	43.56 ± 0.15	48.98 ± 0.22
tg128	-	-	18.27 ± 0.16	28.79 ± 0.08	36.97 ± 0.11	42.54 ± 0.10	48.26 ± 0.15
tg256	-	-	17.90 ± 0.03	27.96 ± 0.30	35.95 ± 0.19	41.12 ± 0.13	47.26 ± 0.10



3. S1: Qwen3.6-35B-A3B-BF16 官方原始 BF16，不量化，作为基准

65G Qwen3.6-35B-A3B-bf16.gguf

代码块

```
## 测试的时候不加MTP
python3 convert_hf_to_gguf.py \
  /data3/huangxin/model_list/Qwen3.6-35B-A3B \
  --outfile /data3/huangxin/model_list/Qwen3.6-35B-A3B/Qwen3.6-35B-A3B-bf16.gguf \
  --outtype bf16 \
  --no-mtp
```

- 不开启TL2
  - F16.GGUF

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （token s / s）	Thread = 2 （token s / s）	Thread = 4 （token s / s）	Thread = 8 （token s / s）	Thread = 12 （token s / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	23.87 ± 0.11	44.93 ± 0.10	62.88 ± 1.72	77.38 ± 0.67	111.29 ± 0.41
pp256	-	-	24.70 ± 0.02	46.82 ± 0.04	66.63 ± 0.06	81.22 ± 0.28	110.33 ± 21.24
pp512	-	-	25.06 ± 0.12	47.24 ± 0.12	66.79 ± 0.14	84.89 ± 1.27	114.64 ± 0.35
pp1024	-	-	24.92 ± 0.06	47.22 ± 0.12	66.85 ± 0.30	85.63 ± 0.24	111.32 ± 4.18
tg16	-	-	5.69 ± 0.01	9.19 ± 0.03	11.30 ± 0.02	12.82 ± 0.01	13.95 ± 0.09
pp32	-	-	5.68 ± 0.01	9.22 ± 0.03	11.29 ± 0.02	12.95 ± 0.01	14.07 ± 0.03
tg64	-	-	5.71 ± 0.02	9.14 ± 0.08	11.33 ± 0.02	12.95 ± 0.01	14.10 ± 0.40
tg128	-	-	5.71 ± 0.00	9.15 ± 0.03	11.29 ± 0.00	12.95 ± 0.01	14.38 ± 0.03

tg256	-	-	5.69 ± 0.01	9.15 ± 0.04	11.25 ± 0.01	12.88 ± 0.02	14.31 ± 0.08

代码块

```
## 测试的时候不加MTP
/home/huangxin/code_list/bitnet-moe-script/build_script/build_bin_upstream/bin/llama-quantize \
   /data3/huangxin/model_list/Qwen3.6-35B-A3B/Qwen3.6-35B-A3B-bf16.gguf \
   /data3/huangxin/model_list/Qwen3.6-35B-A3B/Qwen3.6-35B-A3B-Q4_0.gguf \
   Q4_0
```

- Q4_0.GGUF

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	51.15 ± 0.09	86.85 ± 6.89	114.46 ± 6.17	150.83 ± 9.19	192.39 ± 3.91
pp256	-	-	51.30 ± 0.13	94.88 ± 0.47	123.62 ± 1.27	163.67 ± 0.50	192.56 ± 0.37
pp512	-	-	51.30 ± 0.01	93.18 ± 0.40	123.15 ± 0.41	161.54 ± 0.74	164.45 ± 0.68
pp1024	-	-	50.74 ± 0.16	92.51 ± 0.24	121.88 ± 0.19	159.61 ± 1.20	164.29 ± 0.36
tg16	-	-	13.65 ± 0.02	19.70 ± 0.08	23.44 ± 0.04	25.35 ± 0.01 (预期应43toks/s)	25.57 ± 0.12
pp32	-	-	13.66 ± 0.04	19.70 ± 0.05	23.55 ± 0.01	25.61 ± 0.06	25.30 ± 0.17
tg64	-	-	13.61 ± 0.03	19.76 ± 0.06	23.49 ± 0.05	25.54 ± 0.05	27.49 ± 0.04
tg128	-	-	13.67 ± 0.0	19.86 ± 0.23	23.56 ± 0.01	25.71 ± 0.02	27.48 ± 0.01

tg256	-	-	13.49 ± 0.01	19.49 ± 0.02	23.24 ± 0.0	25.52 ± 0.02	25.70 ± 0.01

其中在16线程数，Qwen3-30B-A3B的decode吞吐为43tokens/s，但是在Qwen3.6-35B-A3B就只有25tokens/s，原因主要有两个：

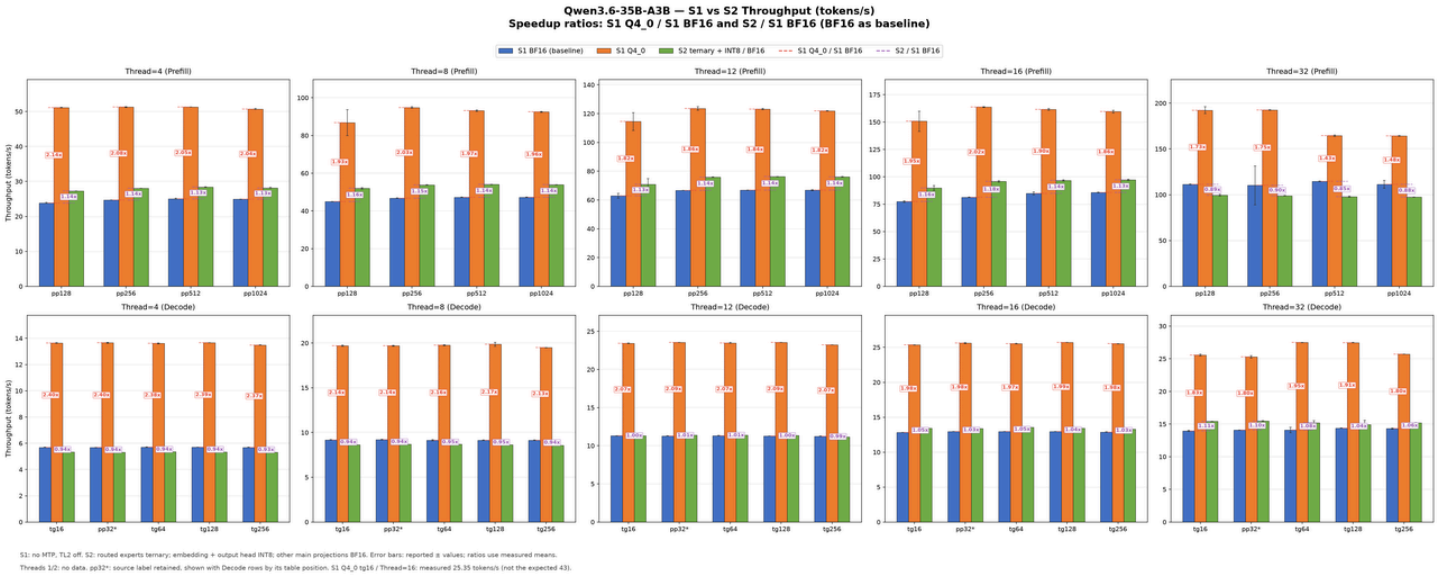
- Qwen3.6 多了 GDN 的执行开销
  - GDN 不只是几个量化矩阵乘法，还包括卷积、门控、归一化和递归状态更新。当前 upstream 的 CPU GDN

  核心实现使用 FP32 运算。Q4_0 缩小了权重，并不会把这些状态更新和其他运算也全部变成 4 bit。GDN 的长上下文内存优势，也不意味着在几十到几百 token 的短上下文测试中，CPU decode一定比普通注意力更快。
- Qwen3.6 输出头扩大了约 63%
  - 新模型的词表更大，每次 decode 都要计算更大的输出头。这种开销在逐 token 生成时尤其直接；prefill 则可以把部分输出开销分摊到多个输入 token。另外，你的两个文件虽然都叫 Q4_0，输出头实际上都保留成了 Q6_K。这是实际 GGUF中的类型，并不是新模型没有正确量化。

项目	Qwen3-30B-A3B	Qwen3.6-35B-A3B
层数	48	40
序列处理模块	48 层完整注意力	10 层完整注意力 + 30 层 GDN
每层专家数 / 选中数	128 / 8	256 / 8
专家中间维度	768	512
共享专家	无	有
词表大小	151,936	248,320
GGUF 输出头实际类型	Q6_K	Q6_K
输出头大小	**243.4 MiB**	**397.9 MiB**

4. S2: 路由专家三值量化，Embedding 和输出头 INT8；其余主投影保持 BF16

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	27.29 ± 0.03	51.95 ± 0.34	70.83 ± 3.93	89.76 ± 2.18	99.56 ± 0.90
pp256	-	-	28.04 ± 0.02	53.80 ± 0.12	75.92 ± 0.26	95.75 ± 0.58	98.94 ± 0.10
pp512	-	-	28.39 ± 0.06	54.03 ± 0.05	76.21 ± 0.08	96.71 ± 0.57	97.98 ± 0.62
pp1024	-	-	28.16 ± 0.12	53.88 ± 0.05	76.10 ± 0.26	97.17 ± 0.58	97.49 ± 0.13
tg16	-	-	5.34 ± 0.01	8.65 ± 0.02	11.33 ± 0.03	13.41 ± 0.02	15.42 ± 0.02
pp32	-	-	5.32 ± 0.00	8.69 ± 0.03	11.40 ± 0.02	13.38 ± 0.10	15.46 ± 0.04
tg64	-	-	5.35 ± 0.00	8.70 ± 0.00	11.40 ± 0.02	13.58 ± 0.07	15.21 ± 0.31
tg128	-	-	5.34 ± 0.01	8.65 ± 0.00	11.34 ± 0.01	13.43 ± 0.01	14.94 ± 0.62
tg256	-	-	5.31 ± 0.00	8.58 ± 0.01	11.14 ± 0.00	13.32 ± 0.01	15.21 ± 0.05



S1: no MTP, TL2 off. S2: routed experts ternary; embedding + output head INT8; other main projections BF16. Error bars: reported ± values; ratios use measured means.
Threads 1/2: no data. pp32*: source label retained; shown with Decode rows by its table position. S1 Q4_0 tg16 / Thread=16: measured 25.35 tokens/s (not the expected 43).

实际存储情况

模块	张量数量	实际格式
路由专家 FC1/FC2	80	三值 {-1,0,+1}，packed2 存储，配 BF16 scale
Embedding	1	INT8 codes + BF16 reciprocal scale
输出头 LM head	1	INT8 codes + BF16 reciprocal scale
共享专家主投影	120	BF16
完整注意力主投影	40	BF16
GDN 主投影	150	BF16

需要注意：
- 专家显示为 I32，只是每个 INT32 容器打包 16 个三值代码，实际是 2 bit/weight。
- 按文档要求，30 个 GDN A_log 和 30 个 GDN 输出 norm 从 BF16 无损提升为 FP32。它们是保护名单中的小参数，不违反“其余主投影保持 BF16”的要求。
- 不包含 vision 和 MTP 权重。

已完成的核对

- 全量检查专家编码：没有非法保留编码 10。
- 全量检查 scale：全部为有限正值。
- 全量检查 Embedding/head codes：全部在 [-127,127]。
- 775 个张量及整个 GGUF 的 SHA256 均与 manifest 一致。
- 从本地官方 BF16 源权重抽样重新量化 124 行，涉及 171,008 个 codes 和 1,336 个 scales，结果完全一致。
- 抽查未量化投影的 228 行，经过必要的可逆布局对应后，与原 BF16 值完全一致。

空间也与文档吻合：

权重及 scale：12,451,875,456 bytes = 11.5967 GiB
GGUF 头部等： 10,992,928 bytes
文件总大小：12,462,868,384 bytes

结论限定在权重配置和格式合规性：源权重量化数值采用抽样复核，不是全模型重新编码；这也不等于已经通过任务质量评测或证明 CPU 加速有效。

5. S3: S2 基础上，再把共享专家投影三值化

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	26.55 ± 0.02	49.45 ± 1.00	69.27 ± 3.13	87.73 ± 6.41	95.20 ± 1.33

pp256	-	-	27.22 ± 0.06	51.45 ± 0.11	73.02 ± 0.09	93.97 ± 0.44	96.43 ± 0.02
pp512	-	-	27.39 ± 0.04	51.58 ± 0.18	72.73 ± 0.08	93.79 ± 1.29	94.77 ± 0.91
pp1024	-	-	27.06 ± 0.02	51.19 ± 0.19	72.05 ± 0.01	93.89 ± 0.70	94.34 ± 0.24
tg16	-	-	5.12 ± 0.00	7.99 ± 0.01	10.12 ± 0.02	12.43 ± 0.05	14.69 ± 0.02
pp32	-	-	5.11 ± 0.00	7.98 ± 0.01	9.99 ± 0.04	12.47 ± 0.00	14.78 ± 0.04
tg64	-	-	5.13 ± 0.00	7.99 ± 0.03	10.21 ± 0.01	12.57 ± 0.01	14.50 ± 0.25
tg128	-	-	5.11 ± 0.01	8.06 ± 0.02	10.11 ± 0.02	12.49 ± 0.01	14.50 ± 0.15
tg256	-	-	5.05 ± 0.01	7.97 ± 0.01	10.00 ± 0.03	12.25 ± 0.01	14.61 ± 0.02

1. 当前 S3 的共享专家仍然是 W2A16

两条路径实际是：

S2: BF16 权重 → GGML 矩阵乘法

S3: packed2 权重 → 解码为 BF16 小块 → GGML BF16 点积

S3 没有减少投影的乘加次数，也没有将共享专家切换成 routed experts 使用的 W2A8 整数点积。

而且，当前实现复用的是 GGML 的
向量点积内核，不等于复用了完整的、高度优化的**矩阵乘法执行路径**。代码中仍然按 token、输出行循环调用 bf16_dot()：

code_list/BitNet/3rdparty/llama.cpp/src/llama-qwen36-s2.cpp:442

因此，**“使用了 SIMD”不代表“能达到原生 GEMM 的吞吐”**。

2. 已有算子实测直接显示了这个问题

此前同机、单线程微基准结果如下。BF16 参考使用预先展开的权重，S3 的时间包含解包：

投影	Tokens	BF16 GGML 参考	当前 S3	S3 耗时倍数
gate/up	1	107.6 µs	345.0 µs	3.21×
down	1	95.6 µs	290.6 µs	3.04×
gate/up	128	2.829 ms	8.846 ms	3.13×
down	128	3.131 ms	10.947 ms	3.50×

证据：/tmp/qwen36-s3-validation.xS9L4b/shared-bench-final.csv

6. S4: S2 基础上，再把完整注意力投影三值化

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-					
pp256	-	-					
pp512	-	-					
pp1024	-	-					
tg16	-	-					

pp32	-	-					
tg64	-	-					
tg128	-	-					
tg256	-	-					

7. S5: S2 基础上，再把 GDN 投影三值化

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-					
pp256	-	-					
pp512	-	-					
pp1024	-	-					
tg16	-	-					
pp32	-	-					
tg64	-	-					
tg128	-	-					
tg256	-	-					

8. S6: S2 基础上，注意力和 GDN 投影都三值化

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）

pp128	-	-					
pp256	-	-					
pp512	-	-					
pp1024	-	-					
tg16	-	-					
pp32	-	-					
tg64	-	-					
tg128	-	-					
tg256	-	-					

9. S7: S6 基础上，再把共享专家投影三值化

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-					
pp256	-	-					
pp512	-	-					
pp1024	-	-					
tg16	-	-					
pp32	-	-					
tg64	-	-					
tg128	-	-					
tg256	-	-					

10. S8: 从 S2 出发，把其余大投影改成 FP8

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-					
pp256	-	-					
pp512	-	-					
pp1024	-	-					
tg16	-	-					
pp32	-	-					
tg64	-	-					
tg128	-	-					
tg256	-	-					

11. S9: 从 S2 出发，把其余大投影改成 INT8

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-					
pp256	-	-					
pp512	-	-					
pp1024	-	-					
tg16	-	-					
pp32	-	-					

tg64	-	-					
tg128	-	-					
tg256	-	-					