v10：Qwen3.6-35B-A3B，BitNet加速比测试

> 核心问题：
>
> 把 Qwen3.6-35B-A3B 的哪些部分量化，能省多少内存、损失多少效果、在 CPU 上能否真正加速？

Qwen 3.6 35A3B bitnet	SWE
S1 (not tuned)	66.40%
S2	63.60%
S8 (fp8)	62.80%
S9 (int8)	60.40%

- S2 S8 S9 其实掉的点不会太多，后面结合一下你那边的 CPU kernel 性能，如果靠谱的话，可以上更多的 sft data 试试
- SWE 是一个软件工程的 benchmark，感觉还挺符合下游应用场景的

1. 实验表格

Setting	Shared expert 投影	Full-attention 投影	GDN 投影	
S1：官方原始 BF16 baseline	BF16	BF16	BF16	69
S2：当前位置，BF16 scales	BF16	BF16	BF16	12
S3：S2 + shared	w1.58	BF16	BF16	12
S4：S2 + full-attention	BF16	w1.58	BF16	11
S5：S2 + GDN	BF16	BF16	w1.58	10
S6：S2 + full-attention + GDN	BF16	w1.58	w1.58	10
S7：S6 + shared	w1.58	w1.58	w1.58	10
S8：S2 其余大 Linear 变 FP8 block	FP8-B128	FP8-B128	FP8-B128	11
S9：S2 其余大 Linear 变 INT8 block	INT8-B128	INT8-B128	INT8-B128	11

方案	要做的事情	
S1 *	官方原始 BF16，不量化，作为基准	
S2 **	Expert三值量化，Embedding 和输出头 INT8；其余主投影保持 BF16	
S3	S2 基础上，再把共享专家投影三值化	
S4	S2 基础上，再把full-attention投影三值化	
S5 *	S2 基础上，再把 GDN 投影三值化	
S6 *	S2 基础上，full-attention和 GDN 投影都三值化	
S7	S6 基础上，再把共享专家投影三值化	
S8 **	从 S2 出发，把其余大Linear改成 FP8	
S9 **	从 S2 出发，把其余大Linear改成 INT8	

2. 在llama.cpp upstream master分支跑Qwen3-30B-A3B看吞吐是多少，自己的BitNet适配是否已经达到SOTA，还有无优化空间。

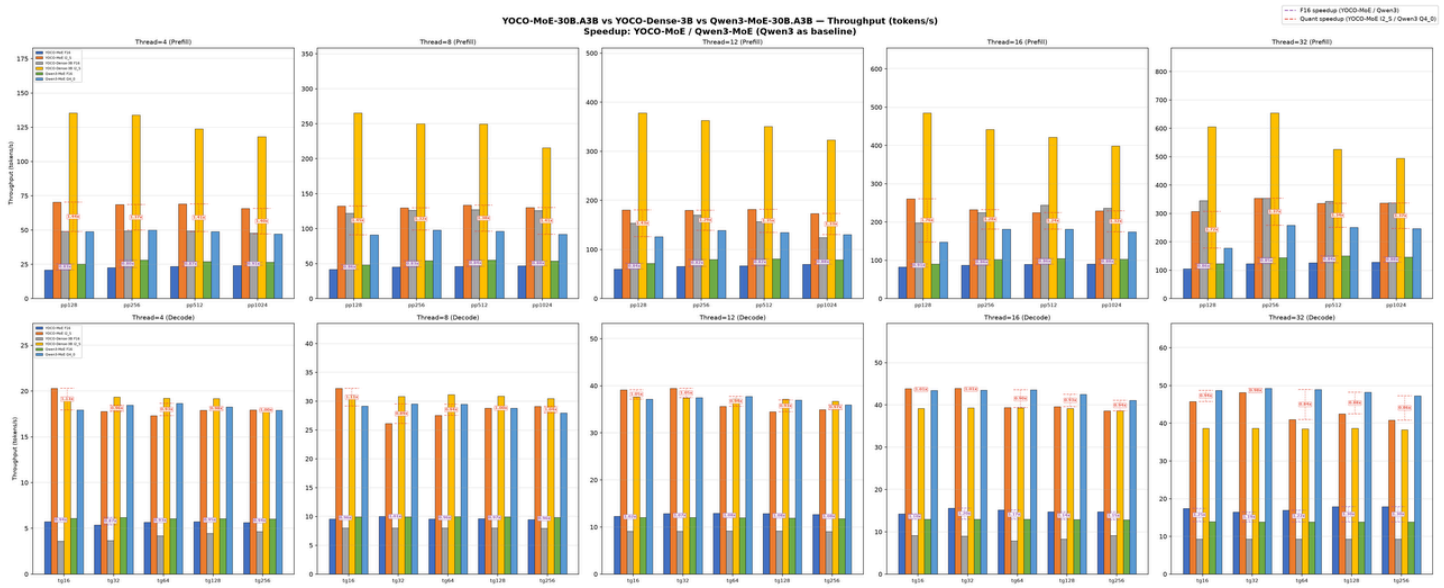
- Qwen3-MoE-30B-A3B，Q4_0
- 不开启TL2
  - F16.GGUF

Model | Thread Number Qwen3-MoE-30B.A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	25.28 ± 0.46	48.41 ± 0.73	71.78 ± 1.10	90.80 ± 2.63	122.83 ± 1.39
pp256	-	-	28.09 ± 0.74	54.41 ± 0.60	79.68 ± 0.61	102.09 ± 0.50	144.65 ± 0.24
pp512	-	-	26.99 ± 0.44	55.11 ± 0.63	81.14 ± 0.99	104.52 ± 0.37	150.41 ± 0.85
pp1024	-	-	26.47 ± 0.44	53.66 ± 0.81	79.12 ± 0.38	102.67 ± 0.15	145.93 ± 2.20
tg16	-	-	6.10 ± 0.07	9.94 ± 0.09	12.03 ± 0.01	12.95 ± 0.05	13.95 ± 0.02
pp32	-	-	6.19 ± 0.02	9.96 ± 0.01	12.03 ± 0.04	12.98 ± 0.01	13.81 ± 0.05

tg64	-	-	6.06 ± 0.01	9.97 ± 0.0	12.00 ± 0.01	12.98 ± 0.0	13.86 ± 0.11
tg128	-	-	6.07 ± 0.01	9.95 ± 0.01	11.93 ± 0.01	12.93 ± 0.01	13.80 ± 0.12
tg256	-	-	6.02 ± 0.01	9.83 ± 0.03	11.81 ± 0.00	12.84 ± 0.01	13.83 ± 0.09

- Q4_0.GGUF

Model | Thread Number Qwen3-MoE-30B.A3B	Thread = 1 （token s / s）	Thread = 2 （token s / s）	Thread = 4 （token s / s）	Thread = 8 （token s / s）	Thread = 12 （token s / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	49.00 ± 0.23	90.98 ± 8.36	125.99 ± 12.78	148.00 ± 3.51	178.48 ± 1.98
pp256	-	-	49.96 ± 0.28	97.91 ± 1.68	139.25 ± 0.46	181.48 ± 1.13	258.09 ± 12.81
pp512	-	-	49.01 ± 0.53	96.48 ± 1.31	134.91 ± 0.72	181.24 ± 0.80	251.21 ± 4.76
pp1024	-	-	47.05 ± 0.30	92.12 ± 0.11	130.17 ± 1.21	174.25 ± 0.20	246.48 ± 1.73
tg16	-	-	17.94 ± 0.50	29.14 ± 0.54	37.17 ± 0.07	43.43 ± 0.27	48.72 ± 1.08
pp32	-	-	18.45 ± 0.40	29.51 ± 0.44	37.46 ± 0.31	43.49 ± 0.49	49.23 ± 0.45
tg64	-	-	18.65 ± 0.05	29.47 ± 0.25	37.77 ± 0.18	43.56 ± 0.15	48.98 ± 0.22
tg128	-	-	18.27 ± 0.16	28.79 ± 0.08	36.97 ± 0.11	42.54 ± 0.10	48.26 ± 0.15
tg256	-	-	17.90 ± 0.03	27.96 ± 0.30	35.95 ± 0.19	41.12 ± 0.13	47.26 ± 0.10



3. S1: Qwen3.6-35B-A3B-BF16 官方原始 BF16，不量化，作为基准

65G　　Qwen3.6-35B-A3B-bf16.gguf

代码块

```
## 测试的时候不加MTP
python3 convert_hf_to_gguf.py \
  /data3/huangxin/model_list/Qwen3.6-35B-A3B \
  --outfile /data3/huangxin/model_list/Qwen3.6-35B-A3B/Qwen3.6-35B-A3B-bf16.gguf \
  --outtype bf16 \
  --no-mtp
```

- 不开启TL2
  - F16.GGUF

Model ｜ Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	23.87 ± 0.11	44.93 ± 0.10	62.88 ± 1.72	77.38 ± 0.67	111.29 ± 0.41

pp256	-	-	24.70 ± 0.02	46.82 ± 0.04	66.63 ± 0.06	81.22 ± 0.28	110.33 ± 21.24
pp512	-	-	25.06 ± 0.12	47.24 ± 0.12	66.79 ± 0.14	84.89 ± 1.27	114.64 ± 0.35
pp1024	-	-	24.92 ± 0.06	47.22 ± 0.12	66.85 ± 0.30	85.63 ± 0.24	111.32 ± 4.18
tg16	-	-	5.69 ± 0.01	9.19 ± 0.03	11.30 ± 0.02	12.82 ± 0.01	13.95 ± 0.09
pp32	-	-	5.68 ± 0.01	9.22 ± 0.03	11.29 ± 0.02	12.95 ± 0.01	14.07 ± 0.03
tg64	-	-	5.71 ± 0.02	9.14 ± 0.08	11.33 ± 0.02	12.95 ± 0.01	14.10 ± 0.40
tg128	-	-	5.71 ± 0.00	9.15 ± 0.03	11.29 ± 0.00	12.95 ± 0.01	14.38 ± 0.03
tg256	-	-	5.69 ± 0.01	9.15 ± 0.04	11.25 ± 0.01	12.88 ± 0.02	14.31 ± 0.08

代码块

```
## 测试的时候不加MTP
/home/huangxin/code_list/bitnet-moe-script/build_script/build_bin_upstream/bin/llama-quantize \
   /data3/huangxin/model_list/Qwen3.6-35B-A3B/Qwen3.6-35B-A3B-bf16.gguf \
   /data3/huangxin/model_list/Qwen3.6-35B-A3B/Qwen3.6-35B-A3B-Q4_0.gguf \
   Q4_0
```

- Q4_0.GGUF

Model ｜ Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	51.15 ± 0.09	86.85 ± 6.89	114.46 ± 6.17	150.83 ± 9.19	192.39 ± 3.91
pp256	-	-	51.30 ± 0.13	94.88 ± 0.47	123.62 ± 1.27	163.67 ± 0.50	192.56 ± 0.37

pp512	-	-	51.30 ± 0.01	93.18 ± 0.40	123.15 ± 0.41	161.54 ± 0.74	164.45 ± 0.68
pp1024	-	-	50.74 ± 0.16	92.51 ± 0.24	121.88 ± 0.19	159.61 ± 1.20	164.29 ± 0.36
tg16	-	-	13.65 ± 0.02	19.70 ± 0.08	23.44 ± 0.04	25.35 ± 0.01 (预期应 43toks/s)	25.57 ± 0.12
pp32	-	-	13.66 ± 0.04	19.70 ± 0.05	23.55 ± 0.01	25.61 ± 0.06	25.30 ± 0.17
tg64	-	-	13.61 ± 0.03	19.76 ± 0.06	23.49 ± 0.05	25.54 ± 0.05	27.49 ± 0.04
tg128	-	-	13.67 ± 0.0	19.86 ± 0.23	23.56 ± 0.01	25.71 ± 0.02	27.48 ± 0.01
tg256	-	-	13.49 ± 0.01	19.49 ± 0.02	23.24 ± 0.0	25.52 ± 0.02	25.70 ± 0.01

其中在16线程数，Qwen3-30B-A3B的decode吞吐为43tokens/s，但是在Qwen3.6-35B-A3B就只有25tokens/s，原因主要有两个：

- Qwen3.6 多了 GDN 的执行开销
  - GDN 不只是几个量化矩阵乘法，还包括卷积、门控、归一化和递归状态更新。当前 upstream 的 CPU GDN

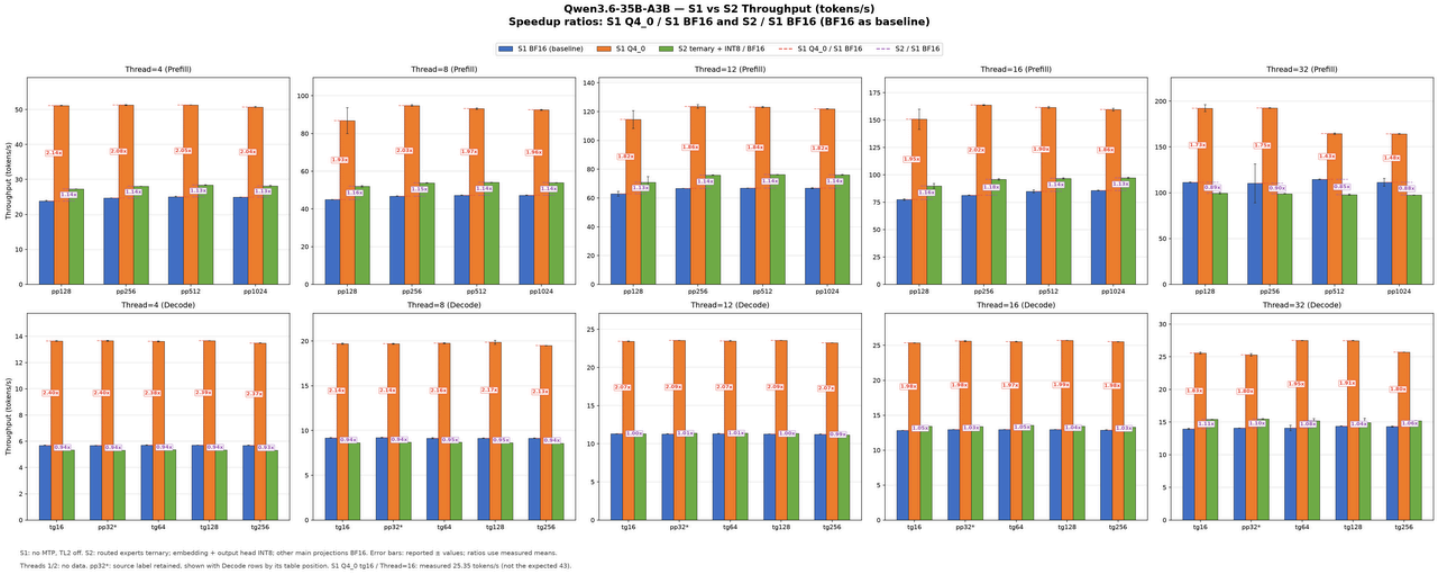
  核心实现使用 FP32 运算。Q4_0 缩小了权重，并不会把这些状态更新和其他运算也全部变成 4 bit。GDN 的长上下文内存优势，也不意味着在几十到几百 token 的短上下文测试中，CPU decode一定比普通注意力更快。
- Qwen3.6 输出头扩大了约 63%
  - 新模型的词表更大，每次 decode 都要计算更大的输出头。这种开销在逐 token 生成时尤其直接；prefill 则可以把部分输出开销分摊到多个输入 token。另外，你的两个文件虽然都叫 Q4_0，输出头实际上都保留成了 Q6_K。这是实际 GGUF中的类型，并不是新模型没有正确量化。

项目	Qwen3-30B-A3B	Qwen3.6-35B-A3B
层数	48	40
序列处理模块	48 层完整注意力	10 层完整注意力 + 30 层 GDN
每层专家数 / 选中数	128 / 8	256 / 8
专家中间维度	768	512
共享专家	无	有
词表大小	151,936	248,320
GGUF 输出头实际类型	Q6_K	Q6_K
输出头大小	**243.4 MiB**	**397.9 MiB**

4. S2: 路由专家三值量化，Embedding 和输出头 INT8；其余主投影保持 BF16

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	27.29 ± 0.03	51.95 ± 0.34	70.83 ± 3.93	89.76 ± 2.18	99.56 ± 0.90
pp256	-	-	28.04 ± 0.02	53.80 ± 0.12	75.92 ± 0.26	95.75 ± 0.58	98.94 ± 0.10
pp512	-	-	28.39 ± 0.06	54.03 ± 0.05	76.21 ± 0.08	96.71 ± 0.57	97.98 ± 0.62
pp1024	-	-	28.16 ± 0.12	53.88 ± 0.05	76.10 ± 0.26	97.17 ± 0.58	97.49 ± 0.13
tg16	-	-	5.34 ± 0.01	8.65 ± 0.02	11.33 ± 0.03	13.41 ± 0.02	15.42 ± 0.02

pp32	-	-	5.32 ± 0.00	8.69 ± 0.03	11.40 ± 0.02	13.38 ± 0.10	15.46 ± 0.04
tg64	-	-	5.35 ± 0.00	8.70 ± 0.00	11.40 ± 0.02	13.58 ± 0.07	15.21 ± 0.31
tg128	-	-	5.34 ± 0.01	8.65 ± 0.00	11.34 ± 0.01	13.43 ± 0.01	14.94 ± 0.62
tg256	-	-	5.31 ± 0.00	8.58 ± 0.01	11.14 ± 0.00	13.32 ± 0.01	15.21 ± 0.05



S1: no MTP, TL2 off. S2: routed experts ternary; embedding + output head INT8; other main projections BF16. Error bars: reported ± values; ratios use measured means.
Threads 1/2: no data. pp32*: source label retained, shown with Decode rows by its table position. S1 Q4_0 tg16 / Thread=16: measured 25.35 tokens/s (not the expected 43).

实际存储情况

模块	张量数量	实际格式
路由专家 FC1/FC2	80	三值 {-1,0,+1}，packed2 存储，配 BF16 scale
Embedding	1	INT8 codes + BF16 reciprocal scale
输出头 LM head	1	INT8 codes + BF16 reciprocal scale
共享专家主投影	120	BF16
完整注意力主投影	40	BF16
GDN 主投影	150	BF16

需要注意：
- 专家显示为 I32，只是每个 INT32 容器打包 16 个三值代码，实际是 2 bit/weight。
- 按文档要求，30 个 GDN A_log 和 30 个 GDN 输出 norm 从 BF16 无损提升为 FP32。它们是保护名单中的小参数，不违反“其余主投影保持 BF16”的要求。
- 不包含 vision 和 MTP 权重。

已完成的核对

- 全量检查专家编码：没有非法保留编码 10。
- 全量检查 scale：全部为有限正值。
- 全量检查 Embedding/head codes：全部在 [-127,127]。
- 775 个张量及整个 GGUF 的 SHA256 均与 manifest 一致。
- 从本地官方 BF16 源权重抽样重新量化 124 行，涉及 171,008 个 codes 和 1,336 个 scales，结果完全一致。
- 抽查未量化投影的 228 行，经过必要的可逆布局对应后，与原 BF16 值完全一致。

空间也与文档吻合：

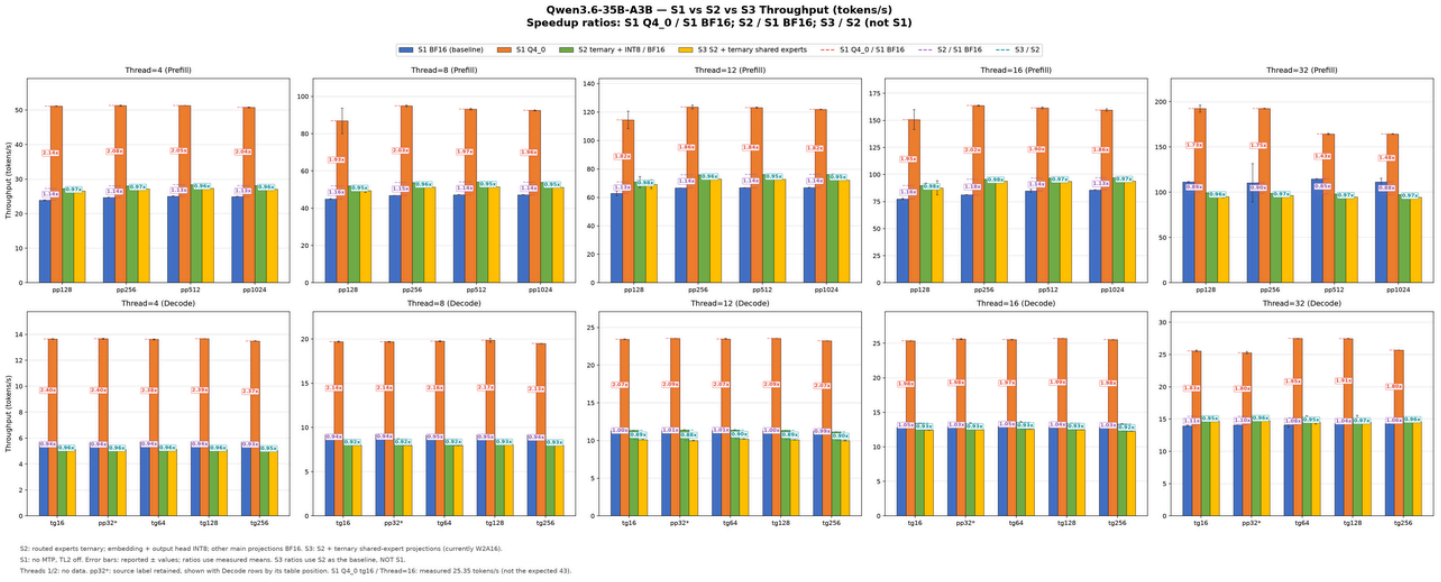
权重及 scale：12,451,875,456 bytes = 11.5967 GiB
GGUF 头部等： 10,992,928 bytes
文件总大小：12,462,868,384 bytes

结论限定在权重配置和格式合规性：源权重量化数值采用抽样复核，不是全模型重新编码；这也不等于已经通过任务质量评测或证明 CPU 加速有效。

5. S3: S2 基础上，再把共享专家投影三值化

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	26.55 ± 0.02	49.45 ± 1.00	69.27 ± 3.13	87.73 ± 6.41	95.20 ± 1.33

pp256	-	-	27.22 ± 0.06	51.45 ± 0.11	73.02 ± 0.09	93.97 ± 0.44	96.43 ± 0.02
pp512	-	-	27.39 ± 0.04	51.58 ± 0.18	72.73 ± 0.08	93.79 ± 1.29	94.77 ± 0.91
pp1024	-	-	27.06 ± 0.02	51.19 ± 0.19	72.05 ± 0.01	93.89 ± 0.70	94.34 ± 0.24
tg16	-	-	5.12 ± 0.00	7.99 ± 0.01	10.12 ± 0.02	12.43 ± 0.05	14.69 ± 0.02
pp32	-	-	5.11 ± 0.00	7.98 ± 0.01	9.99 ± 0.04	12.47 ± 0.00	14.78 ± 0.04
tg64	-	-	5.13 ± 0.00	7.99 ± 0.03	10.21 ± 0.01	12.57 ± 0.01	14.50 ± 0.25
tg128	-	-	5.11 ± 0.01	8.06 ± 0.02	10.11 ± 0.02	12.49 ± 0.01	14.50 ± 0.15
tg256	-	-	5.05 ± 0.01	7.97 ± 0.01	10.00 ± 0.03	12.25 ± 0.01	14.61 ± 0.02



1. 当前 S3 的共享专家仍然是 W2A16

两条路径实际是：

S2：BF16 权重 → GGML 矩阵乘法

S3：packed2 权重 → 解码为 BF16 小块 → GGML BF16 点积

S3 没有减少投影的乘加次数，也没有将共享专家切换成 routed experts 使用的 W2A8 整数点积。

而且，当前实现复用的是 GGML 的
向量点积内核，不等于复用了完整的、高度优化的矩阵乘法执行路径。代码中仍然按 token、输出行循环调用 bf16_dot()：

code_list/BitNet/3rdparty/llama.cpp/src/llama-qwen36-s2.cpp:442

因此，“使用了 SIMD”不代表“能达到原生 GEMM 的吞吐”。

2. 已有算子实测直接显示了这个问题

此前同机、单线程微基准结果如下。BF16 参考使用预先展开的权重，S3 的时间包含解包：

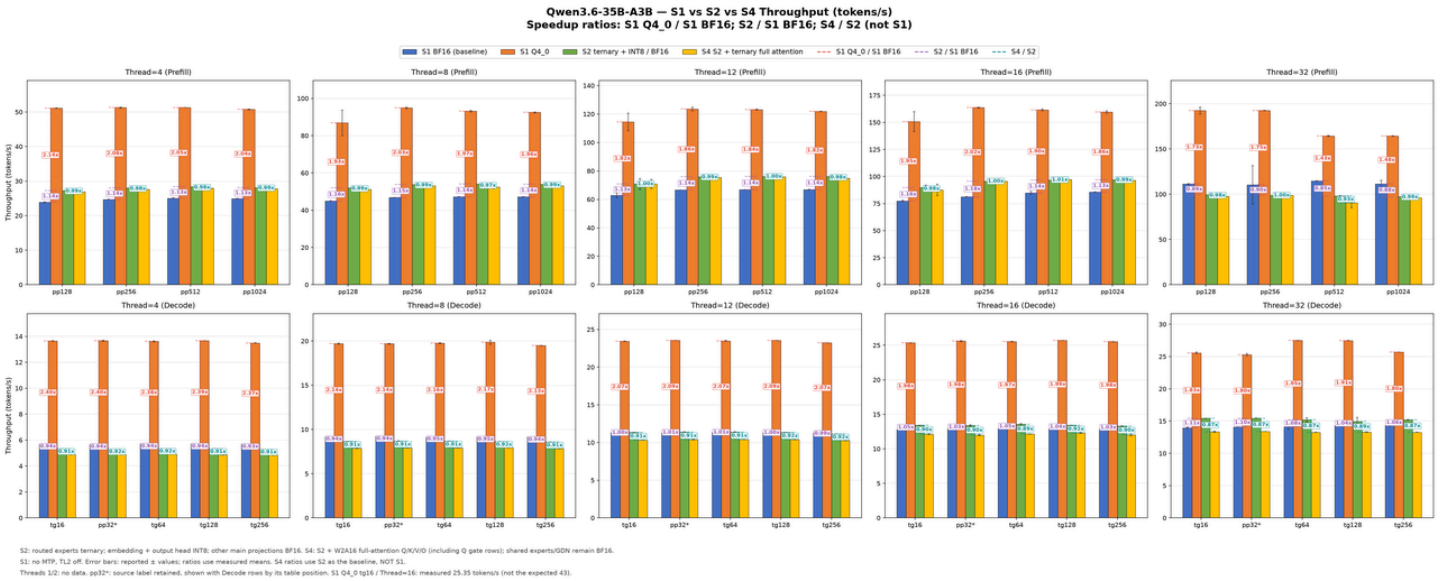
投影	Tokens	BF16 GGML 参考	当前 S3	S3 耗时倍数
gate/up	1	107.6 µs	345.0 µs	3.21×
down	1	95.6 µs	290.6 µs	3.04×
gate/up	128	2.829 ms	8.846 ms	3.13×
down	128	3.131 ms	10.947 ms	3.50×

证据：/tmp/qwen36-s3-validation.xS9L4b/shared-bench-final.csv

6. S4: S2 基础上，再把full-attention投影三值化

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	26.92 ± 0.16	51.25 ± 1.06	70.84 ± 3.16	87.63 ± 5.16	97.92 ± 0.22
pp256	-	-	27.58 ± 0.10	53.08 ± 0.26	75.44 ± 0.26	95.57 ± 0.17	98.75 ± 0.22
pp512	-	-	27.93 ± 0.07	52.47 ± 1.01	75.98 ± 0.15	97.20 ± 0.43	90.65 ± 5.70

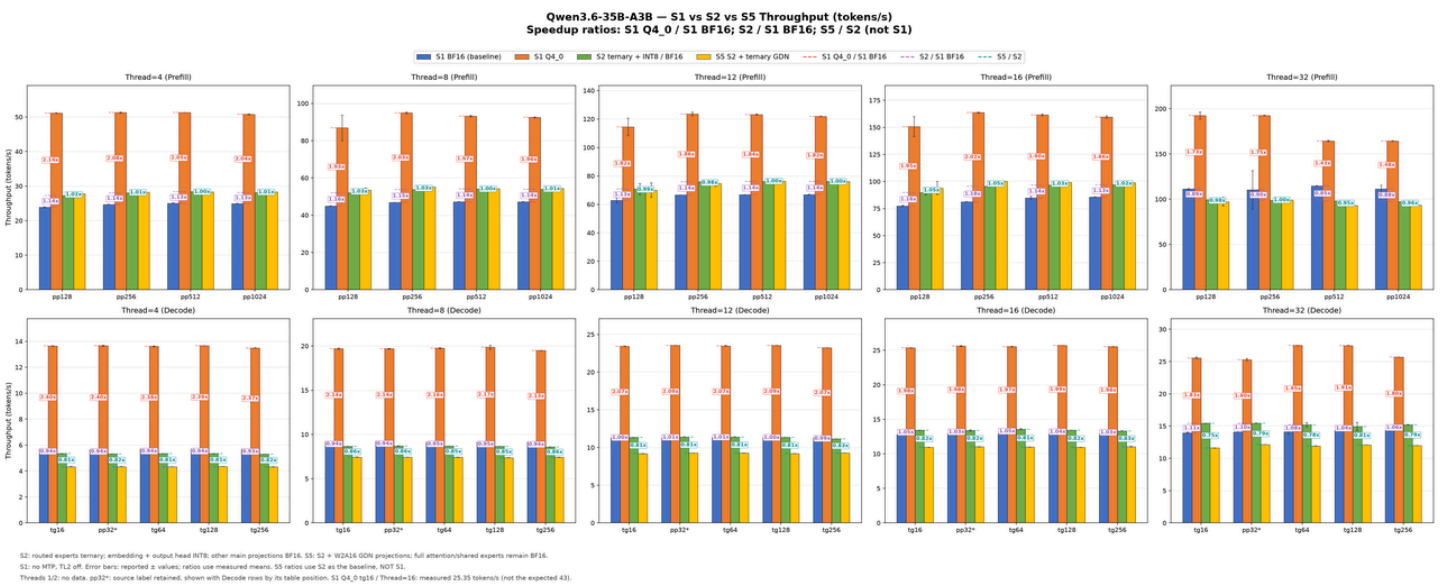
pp1024	-	-	27.83 ± 0.09	53.20 ± 0.15	74.90 ± 0.02	96.42 ± 0.40	96.30 ± 0.40
tg16	-	-	4.88 ± 0.01	7.88 ± 0.02	10.32 ± 0.01	12.12 ± 0.03	13.35 ± 0.09
pp32	-	-	4.88 ± 0.01	7.92 ± 0.01	10.39 ± 0.04	11.99 ± 0.10	13.40 ± 0.01
tg64	-	-	4.92 ± 0.00	7.91 ± 0.01	10.40 ± 0.01	12.15 ± 0.04	13.27 ± 0.01
tg128	-	-	4.87 ± 0.02	7.93 ± 0.01	10.39 ± 0.00	12.29 ± 0.04	13.30 ± 0.06
tg256	-	-	4.83 ± 0.01	7.83 ± 0.02	10.27 ± 0.02	12.04 ± 0.17	13.26 ± 0.02



7. S5: S2 基础上，再把 GDN 投影三值化

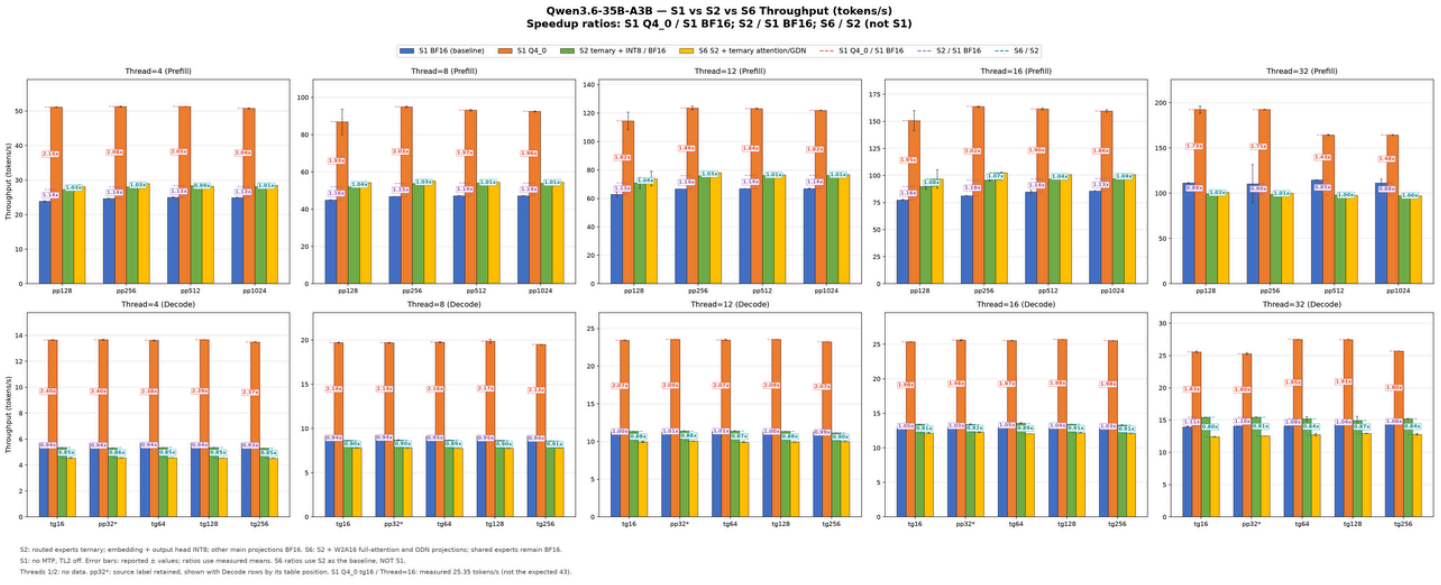
Model ｜ Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	27.82 ± 0.04	53.47 ± 1.14	70.00 ± 5.12	94.05 ± 6.03	97.31 ± 4.75
pp256	-	-					

			28.27 ± 0.08	55.20 ± 0.16	74.58 ± 1.72	100.24 ± 0.10	99.27 ± 0.31
pp512	-	-	28.30 ± 0.03	54.20 ± 0.12	76.42 ± 0.13	99.17 ± 0.11	93.07 ± 0.07
pp1024	-	-	28.34 ± 0.14	54.42 ± 0.34	76.09 ± 0.22	98.90 ± 0.24	93.52 ± 0.13
tg16	-	-	4.34 ± 0.01	7.44 ± 0.02	9.19 ± 0.02	10.94 ± 0.03	11.61 ± 0.01
pp32	-	-	4.34 ± 0.01	7.44 ± 0.01	9.29 ± 0.01	11.03 ± 0.01	12.15 ± 0.01
tg64	-	-	4.34 ± 0.00	7.42 ± 0.02	9.27 ± 0.01	10.98 ± 0.03	11.93 ± 0.01
tg128	-	-	4.35 ± 0.00	7.38 ± 0.01	9.19 ± 0.00	10.95 ± 0.02	12.10 ± 0.01
tg256	-	-	4.33 ± 0.01	7.42 ± 0.01	9.29 ± 0.00	11.04 ± 0.03	12.00 ± 0.01



8. S6: S2 基础上，full-attention和 GDN 投影都三值化

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	28.17 ± 0.50	54.24 ± 0.50	73.89 ± 5.18	96.68 ± 8.56	101.19 ± 1.26
pp256	-	-	28.98 ± 0.23	55.21 ± 0.06	78.04 ± 0.26	102.63 ± 0.41	100.24 ± 0.19
pp512	-	-	28.21 ± 0.11	54.58 ± 0.02	76.62 ± 0.06	100.95 ± 0.17	97.74 ± 0.45
pp1024	-	-	28.50 ± 0.06	54.66 ± 0.37	76.84 ± 0.06	100.97 ± 0.06	97.04 ± 0.17
tg16	-	-	4.55 ± 0.04	7.80 ± 0.02	9.95 ± 0.08	12.14 ± 0.06	12.41 ± 0.04
pp32	-	-	4.56 ± 0.01	7.80 ± 0.02	10.07 ± 0.02	12.26 ± 0.03	12.57 ± 0.01
tg64	-	-	4.56 ± 0.00	7.77 ± 0.01	9.93 ± 0.05	12.04 ± 0.01	12.75 ± 0.19
tg128	-	-	4.55 ± 0.00	7.76 ± 0.01	9.94 ± 0.02	12.18 ± 0.03	12.95 ± 0.04
tg256	-	-	4.52 ± 0.01	7.81 ± 0.00	10.01 ± 0.01	12.07 ± 0.01	12.79 ± 0.13



9. S7: S6 基础上，再把共享专家投影三值化

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-					
pp256	-	-					
pp512	-	-					
pp1024	-	-					
tg16	-	-					
pp32	-	-					
tg64	-	-					
tg128	-	-					
tg256	-	-					

10. S8: 从 S2 出发，把其余大Linear改成 FP8

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-					
pp256	-	-					
pp512	-	-					
pp1024	-	-					
tg16	-	-					
pp32	-	-					

tg64	-	-					
tg128	-	-					
tg256	-	-					

11. S9: 从 S2 出发，把其余大Linear改成 INT8

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-					
pp256	-	-					
pp512	-	-					
pp1024	-	-					
tg16	-	-					
pp32	-	-					
tg64	-	-					
tg128	-	-					
tg256	-	-					

12. 模型结构解析

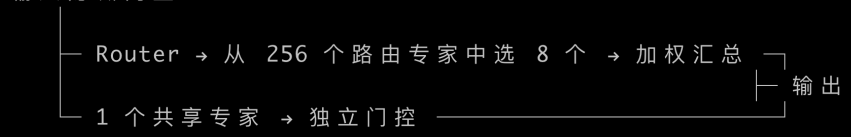
模型结构：30 层 Gated DeltaNet + 10 层全注意力，然后是MoE，其中expert权重占约 93%，但每个 token 每层只用 8/256，按实际参与计算的线性权重粗算，S2 的读取量降幅对应约 1.62倍的理想带宽收益，而不是文件压缩带来的约 5.6倍。



图中省略了每层的归一化和残差连接。具体为：

结构	本地模型配置	作用
GDN: Gated DeltaNet	30 层，配置中叫 linear_attention	通过门控和递归状态更新，处理序列信息
Full Attention	10 层；16 个 Q 头、2 个 KV 头	使用带输出门控的全注意力处理上下文
MoE	每一层都有，共 40 个 MoE 模块	对每个 token 做专家选择与特征变换
Token Embedding	[248320, 2048]	将 token ID 转换成隐藏向量
LM Head	[248320, 2048]，不与 Embedding 共享权重	将隐藏向量映射到词表分数

每个 MoE 内部：路由专家 + 共享专家



- 路由专家（Routed experts）：每个 token、每一层选择其中 8 个。
- 共享专家（Shared expert）：所有 token 都经过，但输出受门控调节。
- 专家的中间维度都是 512，主干隐藏维度为 2048。

因此，Shared expert 不是与 GDN、Full Attention 并列的第三种注意力，而是每层 MoE 内部的一部分。

35B-A3B 表示约 350 亿总参数、每 token 约 30 亿激活参数，不代表只需要存储 30 亿参数。

按本地文本主干权重统计：

模型中的部分	原始 BF16 大小	在表格中的位置
路由专家	60.0000 GiB	没有单列出来；S2 开始就已经三值量化
共享专家的三个投影	0.2344 GiB	Shared expert 投影 列
10 层全注意力的投影	0.5078 GiB	Full-attention 投影 列
30 层 GDN 的投影	1.8823 GiB	GDN 投影 列
Embedding + LM Head	1.8945 GiB	没有单列出来；S2 开始使用 INT8
Router、Norm、卷积等其余权重	0.0414 GiB	大部分保留原精度，少数按规范提升精度
合计	64.5604 GiB	正是 S1

最关键的一点：路由专家占了原始文本权重约 93%。
所以 S1 → S2 从 64.56 GiB 降到 11.60 GiB，主要是量化路由专家的结果；表格展示的三列，是在这个基础上继续研究的部分。

方案	要做的事情	
S1 *	官方原始 BF16，不量化，作为基准	
S2 **	Expert三值量化，Embedding 和输出头 INT8；其余主投影保持 BF16	
S3	S2 基础上，再把共享专家投影三值化	
S4	S2 基础上，再把full-attention投影三值化	
S5 *	S2 基础上，再把 GDN 投影三值化	
S6 *	S2 基础上，full-attention和 GDN 投影都三值化	
S7	S6 基础上，再把共享专家投影三值化	
S8 **	从 S2 出发，把其余大Linear改成 FP8	
S9 **	从 S2 出发，把其余大Linear改成 INT8	

表格列	对应的投影名称
Shared expert	mlp.shared_expert.{gate_proj, up_proj, down_proj}
Full-attention	self_attn.{q_proj, k_proj, v_proj, o_proj}
GDN	linear_attn.{in_proj_qkv, in_proj_z, in_proj_a, in_proj_b, out_proj}

这里有几个容易混淆的边界：

- GDN 包含 **a、b 两个门控投影**，不只是 qkv、z、out。
- Full-attention 的 q_proj **包含输出门控对应的行**。
- shared_expert.gate_proj 属于共享专家内部投影，在量化范围内。
- 但 Router 的 mlp.gate、独立的 shared_expert_gate **不在这三列新增量化的范围内**。

13. 把模型的所有层都转成bitnet1.58量化

约99.92% 的参数已三值化，文件大小为 8.293 GiB。

模块	张量示例	实际类型
Token Embedding	token_embd.weight	I2_S
路由专家 gate/up/down	ffn_gate_exps、ffn_up_exps、ffn_down_exps	I2_S
共享专家 gate/up/down	ffn_gate_shexp、ffn_up_shexp、ffn_down_shexp	I2_S
全注意力 Q/K/V/O 投影	attn_q、attn_k、attn_v、attn_output	I2_S
GDN QKV 大投影	attn_qkv.weight	I2_S
GDN 输出门控 z 大投影	attn_gate.weight	I2_S
GDN 输出投影	ssm_out.weight	I2_S
LM Head	output.weight	I2_S
MoE 路由器	ffn_gate_inp.weight	F32
共享专家路由门控	ffn_gate_inp_shexp.weight	F32
GDN alpha/beta 小投影	ssm_alpha、ssm_beta	F32
GDN 短卷积	ssm_conv1d.weight	F32
GDN A、dt 参数	ssm_a、ssm_dt.bias	F32
各种 Norm，包括 Q/K Norm	attn_norm、ssm_norm、output_norm 等	F32

模块	参数量	占文本主干总参数
MoE 路由器	20,971,520	0.060505%
共享专家路由门控	81,920	0.000236%
GDN alpha/beta 小投影	3,932,160	0.011345%
GDN 短卷积	983,040	0.002836%
GDN A、dt 参数	1,920	0.00000554%
各种 Norm	174,848	0.000504%
合计	26,145,408，约 2615 万	0.075433%

Model | Thread Number Qwen3.6-35B-A3B	Thread = 1 （tokens / s）	Thread = 2 （tokens / s）	Thread = 4 （tokens / s）	Thread = 8 （tokens / s）	Thread = 12 （tokens / s）	Thread = 16 （tokens / s）	Thread = 32 （tokens / s）
pp128	-	-	67.88 ± 1.25	103.23 ± 0.08	141.09 ± 11.38	209.89 ± 8.08	289.48 ± 2.44
pp256	-	-	68.68 ± 0.26	117.77 ± 9.06	171.94 ± 0.32	217.54 ± 0.51	285.03 ± 1.67
pp512	-	-	63.62 ± 0.27	114.76 ± 1.86	157.41 ± 5.63	198.42 ± 2.90	234.99 ± 0.35
pp1024	-	-	62.76 ± 0.24	113.24 ± 1.32	157.57 ± 1.33	197.56 ± 2.70	215.73 ± 36.82
tg16	-	-	18.36 ± 0.12	25.79 ± 0.09	28.28 ± 0.15	27.25 ± 1.35	29.46 ± 0.06
pp32	-	-	17.40 ± 0.59	25.85 ± 0.20	29.65 ± 0.66	30.10 ± 1.16	28.42 ± 0.59
tg64	-	-	18.18 ± 0.47	25.18 ± 1.43	29.43 ± 1.10	30.08 ± 1.54	29.62 ± 0.02
tg128	-	-	18.02 ± 0.41	25.07 ± 0.88	29.31 ± 0.97	30.36 ± 0.64	29.47 ± 0.83

tg256	-	-	17.69 ± 0.19	24.91 ± 0.62	29.08 ± 0.65	30.26 ± 0.81	29.22 ± 0.71