# v10：Qwen3.6-35B-A3B，BitNet加速比测试

> 核心问题：
>
> 把 Qwen3.6-35B-A3B 的哪些部分量化，能省多少内存、损失多少效果、在 CPU 上能否真正加速？

| Qwen 3.6 35A3B bitnet | SWE |
|---|---|
| S1 (not tuned) | 66.40% |
| S2 | 63.60% |
| S8 (fp8) | 62.80% |
| S9 (int8) | 60.40% |

- S2 S8 S9 其实掉的点不会太多，后面结合一下你那边的 CPU kernel 性能，如果靠谱的话，可以上更多的 sft data 试试
- SWE 是一个软件工程的 benchmark，感觉还挺符合下游应用场景的

## 1. 实验表格

| Setting | Shared expert 投影 | Full-attention 投影 | GDN 投影 | |
|---|---|---|---|---|
| S1：官方原始 BF16 baseline | BF16 | BF16 | BF16 | 69 |
| S2：当前位置，BF16 scales | BF16 | BF16 | BF16 | 12 |
| S3：S2 + shared | w1.58 | BF16 | BF16 | 12 |
| S4：S2 + full-attention | BF16 | w1.58 | BF16 | 11 |
| S5：S2 + GDN | BF16 | BF16 | w1.58 | 10 |
| S6：S2 + full-attention + GDN | BF16 | w1.58 | w1.58 | 10 |
| S7：S6 + shared | w1.58 | w1.58 | w1.58 | 10 |
| S8：S2 其余大 Linear 变 FP8 block | FP8-B128 | FP8-B128 | FP8-B128 | 11 |
| S9：S2 其余大 Linear 变 INT8 block | INT8-B128 | INT8-B128 | INT8-B128 | 11 |

| 方案 | 要做的事情 | |
|---|---|---|
| S1 * | 官方原始 BF16，不量化，作为基准 | |
| S2 ** | Expert三值量化，Embedding 和输出头 INT8；其余主投影保持 BF16 | |
| S3 | S2 基础上，再把共享专家投影三值化 | |
| S4 | S2 基础上，再把full-attention投影三值化 | |
| S5 * | S2 基础上，再把 GDN 投影三值化 | |
| S6 * | S2 基础上，full-attention和 GDN 投影都三值化 | |
| S7 | S6 基础上，再把共享专家投影三值化 | |
| S8 ** | 从 S2 出发，把其余大Linear改成 FP8 | |
| S9 ** | 从 S2 出发，把其余大Linear改成 INT8 | |

## 2. 在llama.cpp upstream master分支跑Qwen3-30B-A3B看吞吐是多少，自己的BitNet适配是否已经达到SOTA，还有无优化空间。

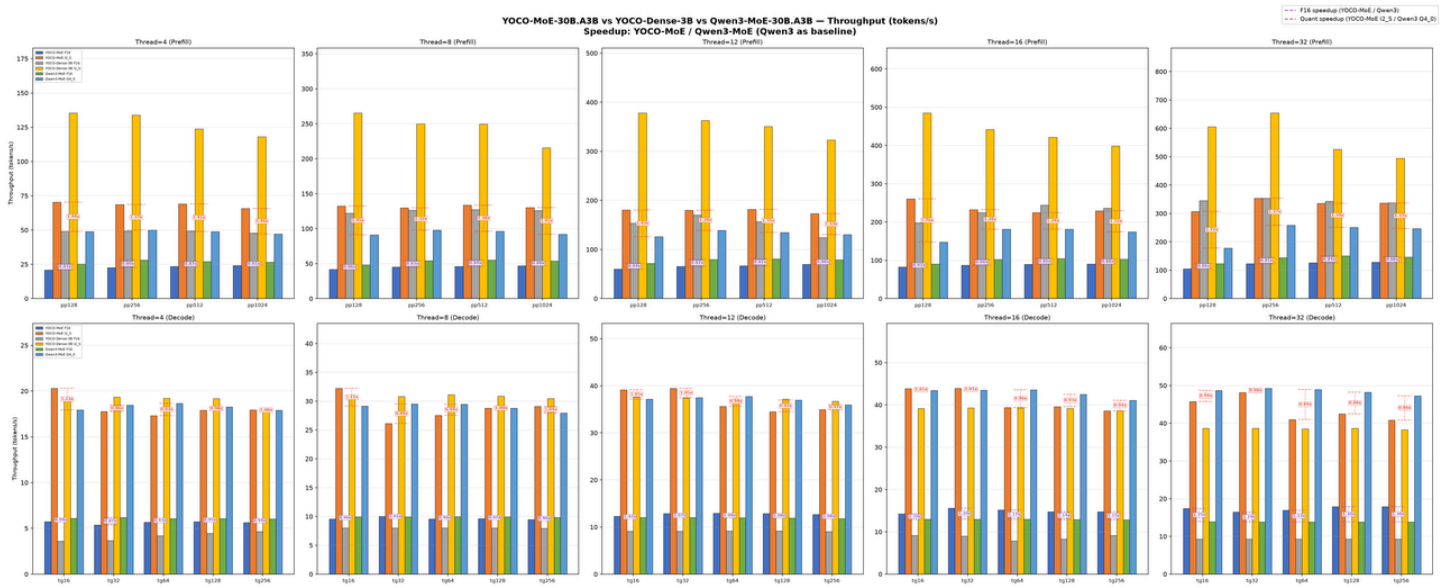
- Qwen3-MoE-30B-A3B，Q4_0
- 不开启TL2
  - F16.GGUF

| Model \| Thread Number<br>Qwen3-MoE-30B.A3B | Thread = 1<br>（tokens / s） | Thread = 2<br>（tokens / s） | Thread = 4<br>（tokens / s） | Thread = 8<br>（tokens / s） | Thread = 12<br>（tokens / s） | Thread = 16<br>（tokens / s） | Thread = 32<br>（tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | 25.28 ± 0.46 | 48.41 ± 0.73 | 71.78 ± 1.10 | 90.80 ± 2.63 | 122.83 ± 1.39 |
| pp256 | - | - | 28.09 ± 0.74 | 54.41 ± 0.60 | 79.68 ± 0.61 | 102.09 ± 0.50 | 144.65 ± 0.24 |
| pp512 | - | - | 26.99 ± 0.44 | 55.11 ± 0.63 | 81.14 ± 0.99 | 104.52 ± 0.37 | 150.41 ± 0.85 |
| pp1024 | - | - | 26.47 ± 0.44 | 53.66 ± 0.81 | 79.12 ± 0.38 | 102.67 ± 0.15 | 145.93 ± 2.20 |
| tg16 | - | - | 6.10 ± 0.07 | 9.94 ± 0.09 | 12.03 ± 0.01 | 12.95 ± 0.05 | 13.95 ± 0.02 |
| pp32 | - | - | 6.19 ± 0.02 | 9.96 ± 0.01 | 12.03 ± 0.04 | 12.98 ± 0.01 | 13.81 ± 0.05 |
| | | | | | | | |

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| tg64 | - | - | 6.06 ± 0.01 | 9.97 ± 0.0 | 12.00 ± 0.01 | 12.98 ± 0.0 | 13.86 ± 0.11 |
| tg128 | - | - | 6.07 ± 0.01 | 9.95 ± 0.01 | 11.93 ± 0.01 | 12.93 ± 0.01 | 13.80 ± 0.12 |
| tg256 | - | - | 6.02 ± 0.01 | 9.83 ± 0.03 | 11.81 ± 0.00 | 12.84 ± 0.01 | 13.83 ± 0.09 |

- Q4_0.GGUF

| Model \| Thread Number<br>Qwen3-MoE-30B.A3B | Thread = 1 （token s / s） | Thread = 2 （token s / s） | Thread = 4 （token s / s） | Thread = 8 （token s / s） | Thread = 12 （token s / s） | Thread = 16 （tokens / s） | Thread = 32 （tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | 49.00 ± 0.23 | 90.98 ± 8.36 | 125.99 ± 12.78 | 148.00 ± 3.51 | 178.48 ± 1.98 |
| pp256 | - | - | 49.96 ± 0.28 | 97.91 ± 1.68 | 139.25 ± 0.46 | 181.48 ± 1.13 | 258.09 ± 12.81 |
| pp512 | - | - | 49.01 ± 0.53 | 96.48 ± 1.31 | 134.91 ± 0.72 | 181.24 ± 0.80 | 251.21 ± 4.76 |
| pp1024 | - | - | 47.05 ± 0.30 | 92.12 ± 0.11 | 130.17 ± 1.21 | 174.25 ± 0.20 | 246.48 ± 1.73 |
| tg16 | - | - | 17.94 ± 0.50 | 29.14 ± 0.54 | 37.17 ± 0.07 | 43.43 ± 0.27 | 48.72 ± 1.08 |
| pp32 | - | - | 18.45 ± 0.40 | 29.51 ± 0.44 | 37.46 ± 0.31 | 43.49 ± 0.49 | 49.23 ± 0.45 |
| tg64 | - | - | 18.65 ± 0.05 | 29.47 ± 0.25 | 37.77 ± 0.18 | 43.56 ± 0.15 | 48.98 ± 0.22 |
| tg128 | - | - | 18.27 ± 0.16 | 28.79 ± 0.08 | 36.97 ± 0.11 | 42.54 ± 0.10 | 48.26 ± 0.15 |
| tg256 | - | - | 17.90 ± 0.03 | 27.96 ± 0.30 | 35.95 ± 0.19 | 41.12 ± 0.13 | 47.26 ± 0.10 |




## 3. S1: Qwen3.6-35B-A3B-BF16 官方原始 BF16，不量化，作为基准

65G　　Qwen3.6-35B-A3B-bf16.gguf

代码块

```
## 测试的时候不加MTP
python3 convert_hf_to_gguf.py \
  /data3/huangxin/model_list/Qwen3.6-35B-A3B \
  --outfile /data3/huangxin/model_list/Qwen3.6-35B-A3B/Qwen3.6-35B-A3B-bf16.gguf \
  --outtype bf16 \
  --no-mtp
```

- 不开启TL2
  - F16.GGUF

| Model ｜ Thread Number<br>Qwen3.6-35B-A3B | Thread = 1<br>（tokens / s） | Thread = 2<br>（tokens / s） | Thread = 4<br>（tokens / s） | Thread = 8<br>（tokens / s） | Thread = 12<br>（tokens / s） | Thread = 16<br>（tokens / s） | Thread = 32<br>（tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | 23.87 ± 0.11 | 44.93 ± 0.10 | 62.88 ± 1.72 | 77.38 ± 0.67 | 111.29 ± 0.41 |

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| pp256 | - | - | 24.70 ± 0.02 | 46.82 ± 0.04 | 66.63 ± 0.06 | 81.22 ± 0.28 | 110.33 ± 21.24 |
| pp512 | - | - | 25.06 ± 0.12 | 47.24 ± 0.12 | 66.79 ± 0.14 | 84.89 ± 1.27 | 114.64 ± 0.35 |
| pp1024 | - | - | 24.92 ± 0.06 | 47.22 ± 0.12 | 66.85 ± 0.30 | 85.63 ± 0.24 | 111.32 ± 4.18 |
| tg16 | - | - | 5.69 ± 0.01 | 9.19 ± 0.03 | 11.30 ± 0.02 | 12.82 ± 0.01 | 13.95 ± 0.09 |
| pp32 | - | - | 5.68 ± 0.01 | 9.22 ± 0.03 | 11.29 ± 0.02 | 12.95 ± 0.01 | 14.07 ± 0.03 |
| tg64 | - | - | 5.71 ± 0.02 | 9.14 ± 0.08 | 11.33 ± 0.02 | 12.95 ± 0.01 | 14.10 ± 0.40 |
| tg128 | - | - | 5.71 ± 0.00 | 9.15 ± 0.03 | 11.29 ± 0.00 | 12.95 ± 0.01 | 14.38 ± 0.03 |
| tg256 | - | - | 5.69 ± 0.01 | 9.15 ± 0.04 | 11.25 ± 0.01 | 12.88 ± 0.02 | 14.31 ± 0.08 |

代码块

```
## 测试的时候不加MTP
/home/huangxin/code_list/bitnet-moe-script/build_script/build_bin_upstream/bin/llama-quantize \
   /data3/huangxin/model_list/Qwen3.6-35B-A3B/Qwen3.6-35B-A3B-bf16.gguf \
   /data3/huangxin/model_list/Qwen3.6-35B-A3B/Qwen3.6-35B-A3B-Q4_0.gguf \
   Q4_0
```

- Q4_0.GGUF

| Model ｜ Thread Number<br>Qwen3.6-35B-A3B | Thread = 1 （tokens / s） | Thread = 2 （tokens / s） | Thread = 4 （tokens / s） | Thread = 8 （tokens / s） | Thread = 12 （tokens / s） | Thread = 16 （tokens / s） | Thread = 32 （tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | 51.15 ± 0.09 | 86.85 ± 6.89 | 114.46 ± 6.17 | 150.83 ± 9.19 | 192.39 ± 3.91 |
| pp256 | - | - | 51.30 ± 0.13 | 94.88 ± 0.47 | 123.62 ± 1.27 | 163.67 ± 0.50 | 192.56 ± 0.37 |

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| pp512 | - | - | 51.30 ± 0.01 | 93.18 ± 0.40 | 123.15 ± 0.41 | 161.54 ± 0.74 | 164.45 ± 0.68 |
| pp1024 | - | - | 50.74 ± 0.16 | 92.51 ± 0.24 | 121.88 ± 0.19 | 159.61 ± 1.20 | 164.29 ± 0.36 |
| tg16 | - | - | 13.65 ± 0.02 | 19.70 ± 0.08 | 23.44 ± 0.04 | 25.35 ± 0.01 (预期应 43toks/s) | 25.57 ± 0.12 |
| pp32 | - | - | 13.66 ± 0.04 | 19.70 ± 0.05 | 23.55 ± 0.01 | 25.61 ± 0.06 | 25.30 ± 0.17 |
| tg64 | - | - | 13.61 ± 0.03 | 19.76 ± 0.06 | 23.49 ± 0.05 | 25.54 ± 0.05 | 27.49 ± 0.04 |
| tg128 | - | - | 13.67 ± 0.0 | 19.86 ± 0.23 | 23.56 ± 0.01 | 25.71 ± 0.02 | 27.48 ± 0.01 |
| tg256 | - | - | 13.49 ± 0.01 | 19.49 ± 0.02 | 23.24 ± 0.0 | 25.52 ± 0.02 | 25.70 ± 0.01 |

其中在16线程数，Qwen3-30B-A3B的decode吞吐为43tokens/s，但是在Qwen3.6-35B-A3B就只有25tokens/s，原因主要有两个：

- Qwen3.6 多了 GDN 的执行开销
  - GDN 不只是几个量化矩阵乘法，还包括卷积、门控、归一化和递归状态更新。当前 upstream 的 CPU GDN

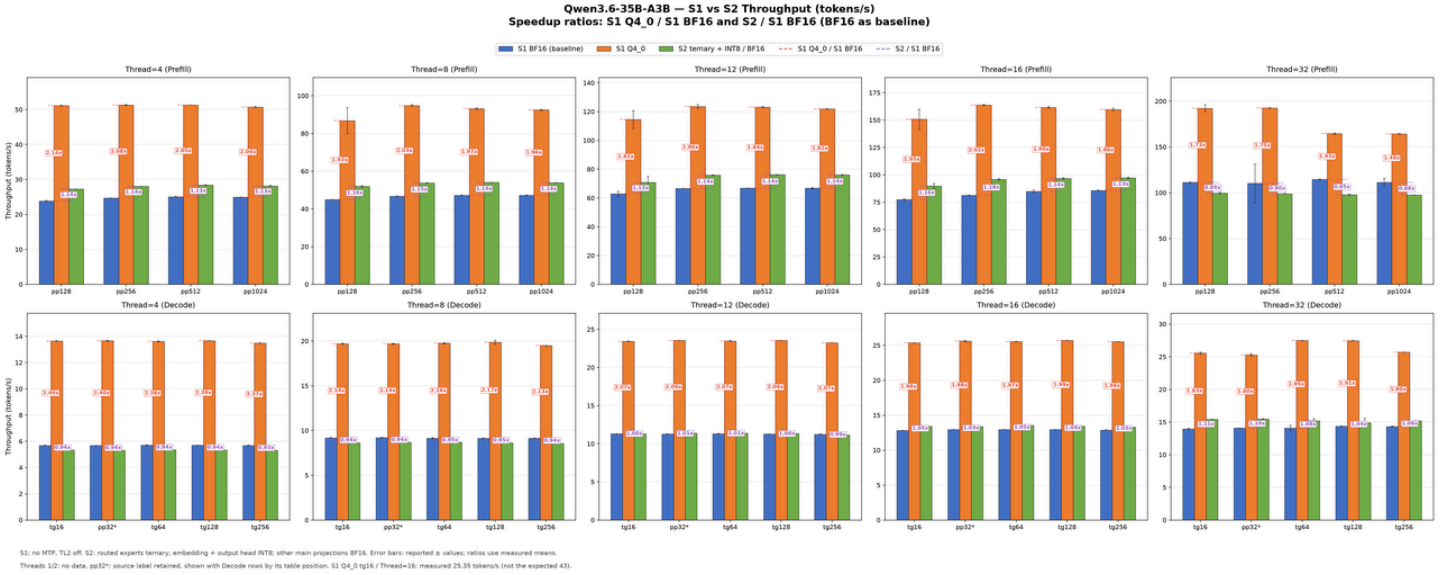
  核心实现使用 FP32 运算。Q4_0 缩小了权重，并不会把这些状态更新和其他运算也全部变成 4 bit。GDN 的长上下文内存优势，也不意味着在几十到几百 token 的短上下文测试中，CPU decode一定比普通注意力更快。
- Qwen3.6 输出头扩大了约 63%
  - 新模型的词表更大，每次 decode 都要计算更大的输出头。这种开销在逐 token 生成时尤其直接；prefill 则可以把部分输出开销分摊到多个输入 token。另外，你的两个文件虽然都叫 Q4_0，输出头实际上都保留成了 Q6_K。这是实际 GGUF中的类型，并不是新模型没有正确量化。

| 项目 | Qwen3-30B-A3B | Qwen3.6-35B-A3B |
|---|---|---|
| 层数 | 48 | 40 |
| 序列处理模块 | 48 层完整注意力 | 10 层完整注意力 + 30 层 GDN |
| 每层专家数 / 选中数 | 128 / 8 | 256 / 8 |
| 专家中间维度 | 768 | 512 |
| 共享专家 | 无 | 有 |
| 词表大小 | 151,936 | 248,320 |
| GGUF 输出头实际类型 | Q6_K | Q6_K |
| 输出头大小 | **243.4 MiB** | **397.9 MiB** |

## 4. S2: 路由专家三值量化，Embedding 和输出头 INT8；其余主投影保持 BF16

| Model \| Thread Number<br>Qwen3.6-35B-A3B | Thread = 1<br>（tokens / s） | Thread = 2<br>（tokens / s） | Thread = 4<br>（tokens / s） | Thread = 8<br>（tokens / s） | Thread = 12<br>（tokens / s） | Thread = 16<br>（tokens / s） | Thread = 32<br>（tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | 27.29 ± 0.03 | 51.95 ± 0.34 | 70.83 ± 3.93 | 89.76 ± 2.18 | 99.56 ± 0.90 |
| pp256 | - | - | 28.04 ± 0.02 | 53.80 ± 0.12 | 75.92 ± 0.26 | 95.75 ± 0.58 | 98.94 ± 0.10 |
| pp512 | - | - | 28.39 ± 0.06 | 54.03 ± 0.05 | 76.21 ± 0.08 | 96.71 ± 0.57 | 97.98 ± 0.62 |
| pp1024 | - | - | 28.16 ± 0.12 | 53.88 ± 0.05 | 76.10 ± 0.26 | 97.17 ± 0.58 | 97.49 ± 0.13 |
| tg16 | - | - | 5.34 ± 0.01 | 8.65 ± 0.02 | 11.33 ± 0.03 | 13.41 ± 0.02 | 15.42 ± 0.02 |

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| pp32 | - | - | 5.32 ± 0.00 | 8.69 ± 0.03 | 11.40 ± 0.02 | 13.38 ± 0.10 | 15.46 ± 0.04 |
| tg64 | - | - | 5.35 ± 0.00 | 8.70 ± 0.00 | 11.40 ± 0.02 | 13.58 ± 0.07 | 15.21 ± 0.31 |
| tg128 | - | - | 5.34 ± 0.01 | 8.65 ± 0.00 | 11.34 ± 0.01 | 13.43 ± 0.01 | 14.94 ± 0.62 |
| tg256 | - | - | 5.31 ± 0.00 | 8.58 ± 0.01 | 11.14 ± 0.00 | 13.32 ± 0.01 | 15.21 ± 0.05 |




S1: no MTP, TL2 off. S2: routed experts ternary; embedding + output head INT8; other main projections BF16. Error bars: reported ± values; ratios use measured means.
Threads 1/2: no data. pp32*: source label retained, shown with Decode rows by its table position. S1 Q4_0 tg16 / Thread=16: measured 25.35 tokens/s (not the expected 43).

实际存储情况

| 模块 | 张量数量 | 实际格式 |
|---|---|---|
| 路由专家 FC1/FC2 | 80 | 三值 {-1,0,+1}，packed2 存储，配 BF16 scale |
| Embedding | 1 | INT8 codes + BF16 reciprocal scale |
| 输出头 LM head | 1 | INT8 codes + BF16 reciprocal scale |
| 共享专家主投影 | 120 | BF16 |
| 完整注意力主投影 | 40 | BF16 |
| GDN 主投影 | 150 | BF16 |

需要注意：
- 专家显示为 I32，只是每个 INT32 容器打包 16 个三值代码，实际是 2 bit/weight。
- 按文档要求，30 个 GDN A_log 和 30 个 GDN 输出 norm 从 BF16 无损提升为 FP32。它们是保护名单中的小参数，不违反“其余主投影保持 BF16”的要求。
- 不包含 vision 和 MTP 权重。

已完成的核对

- 全量检查专家编码：没有非法保留编码 10。
- 全量检查 scale：全部为有限正值。
- 全量检查 Embedding/head codes：全部在 [-127,127]。
- 775 个张量及整个 GGUF 的 SHA256 均与 manifest 一致。
- 从本地官方 BF16 源权重抽样重新量化 124 行，涉及 171,008 个 codes 和 1,336 个 scales，结果完全一致。
- 抽查未量化投影的 228 行，经过必要的可逆布局对应后，与原 BF16 值完全一致。

空间也与文档吻合：

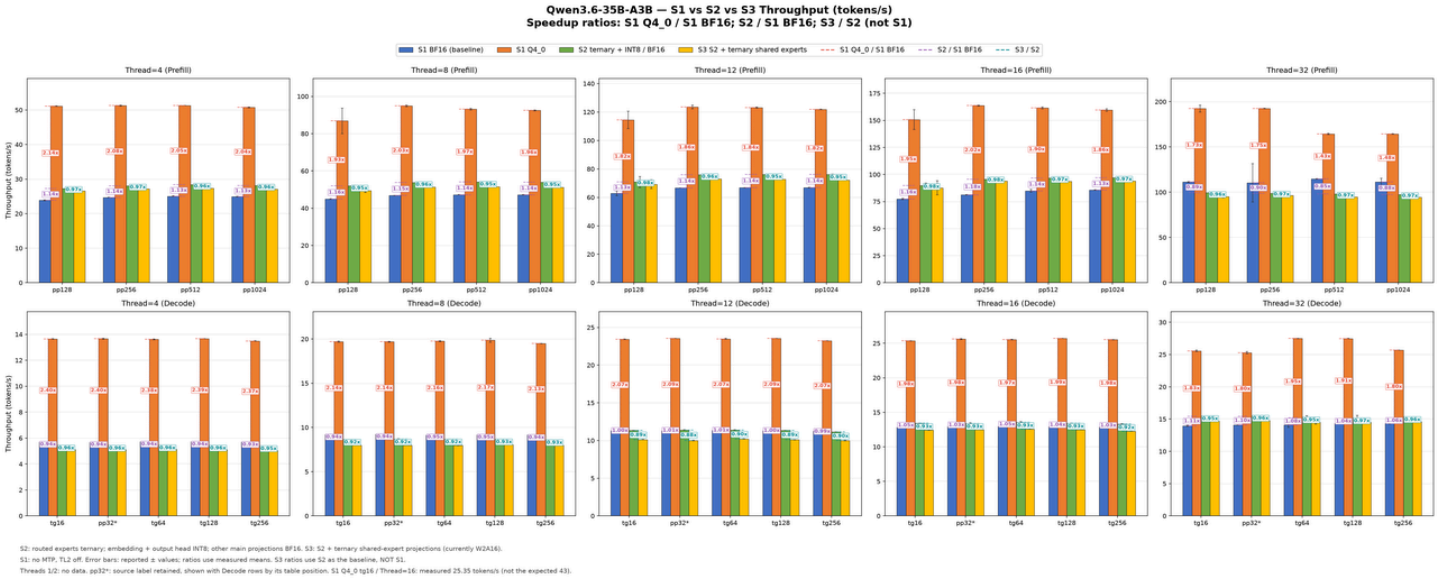
权重及 scale：12,451,875,456 bytes = 11.5967 GiB
GGUF 头部等：  10,992,928 bytes
文件总大小：12,462,868,384 bytes

结论限定在权重配置和格式合规性：源权重量化数值采用抽样复核，不是全模型重新编码；这也不等于已经通过任务质量评测或证明 CPU 加速有效。

## 5. S3: S2 基础上，再把共享专家投影三值化

| Model \| Thread Number<br>Qwen3.6-35B-A3B | Thread = 1<br>（tokens / s） | Thread = 2<br>（tokens / s） | Thread = 4<br>（tokens / s） | Thread = 8<br>（tokens / s） | Thread = 12<br>（tokens / s） | Thread = 16<br>（tokens / s） | Thread = 32<br>（tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | 26.55 ± 0.02 | 49.45 ± 1.00 | 69.27 ± 3.13 | 87.73 ± 6.41 | 95.20 ± 1.33 |

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| pp256 | - | - | 27.22 ± 0.06 | 51.45 ± 0.11 | 73.02 ± 0.09 | 93.97 ± 0.44 | 96.43 ± 0.02 |
| pp512 | - | - | 27.39 ± 0.04 | 51.58 ± 0.18 | 72.73 ± 0.08 | 93.79 ± 1.29 | 94.77 ± 0.91 |
| pp1024 | - | - | 27.06 ± 0.02 | 51.19 ± 0.19 | 72.05 ± 0.01 | 93.89 ± 0.70 | 94.34 ± 0.24 |
| tg16 | - | - | 5.12 ± 0.00 | 7.99 ± 0.01 | 10.12 ± 0.02 | 12.43 ± 0.05 | 14.69 ± 0.02 |
| pp32 | - | - | 5.11 ± 0.00 | 7.98 ± 0.01 | 9.99 ± 0.04 | 12.47 ± 0.00 | 14.78 ± 0.04 |
| tg64 | - | - | 5.13 ± 0.00 | 7.99 ± 0.03 | 10.21 ± 0.01 | 12.57 ± 0.01 | 14.50 ± 0.25 |
| tg128 | - | - | 5.11 ± 0.01 | 8.06 ± 0.02 | 10.11 ± 0.02 | 12.49 ± 0.01 | 14.50 ± 0.15 |
| tg256 | - | - | 5.05 ± 0.01 | 7.97 ± 0.01 | 10.00 ± 0.03 | 12.25 ± 0.01 | 14.61 ± 0.02 |




S2: routed experts ternary; embedding + output head INT8; other main projections BF16. S3: S2 + ternary shared-expert projections (currently W2A16).
S1: no MTP, TL2 off. Error bars: reported ± values; ratios use measured means. S3 ratios use S2 as the baseline, NOT S1.
Threads 1/2: no data. pp32*: source label retained, shown with Decode rows by its table position. S1 Q4_0 tg16 / Thread=16: measured 25.35 tokens/s (not the expected 43).

1. 当前 S3 的共享专家仍然是 W2A16

两条路径实际是：

S2：BF16 权重 → GGML 矩阵乘法

S3：packed2 权重 → 解码为 BF16 小块 → GGML BF16 点积

S3 没有减少投影的乘加次数，也没有将共享专家切换成 routed experts 使用的 W2A8 整数点积。

而且，当前实现复用的是 GGML 的
向量点积内核，不等于复用了完整的、高度优化的矩阵乘法执行路径。代码中仍然按 token、输出行循环调用 bf16_dot()：

code_list/BitNet/3rdparty/llama.cpp/src/llama-qwen36-s2.cpp:442

因此，“使用了 SIMD”不代表“能达到原生 GEMM 的吞吐”。

2. 已有算子实测直接显示了这个问题

此前同机、单线程微基准结果如下。BF16 参考使用预先展开的权重，S3 的时间包含解包：

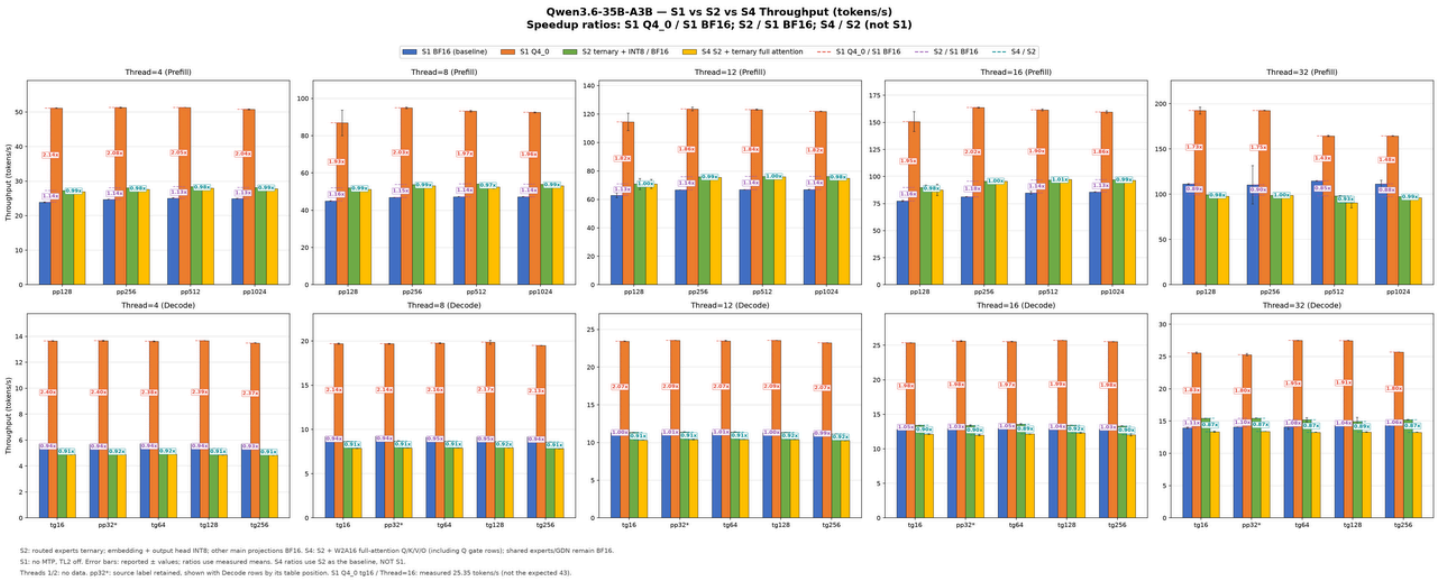
| 投影 | Tokens | BF16 GGML 参考 | 当前 S3 | S3 耗时倍数 |
|---|---|---|---|---|
| gate/up | 1 | 107.6 µs | 345.0 µs | 3.21× |
| down | 1 | 95.6 µs | 290.6 µs | 3.04× |
| gate/up | 128 | 2.829 ms | 8.846 ms | 3.13× |
| down | 128 | 3.131 ms | 10.947 ms | 3.50× |

证据：/tmp/qwen36-s3-validation.xS9L4b/shared-bench-final.csv

## 6. S4: S2 基础上，再把full-attention投影三值化

| Model \| Thread Number<br>Qwen3.6-35B-A3B | Thread = 1<br>（tokens / s） | Thread = 2<br>（tokens / s） | Thread = 4<br>（tokens / s） | Thread = 8<br>（tokens / s） | Thread = 12<br>（tokens / s） | Thread = 16<br>（tokens / s） | Thread = 32<br>（tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | 26.92 ± 0.16 | 51.25 ± 1.06 | 70.84 ± 3.16 | 87.63 ± 5.16 | 97.92 ± 0.22 |
| pp256 | - | - | 27.58 ± 0.10 | 53.08 ± 0.26 | 75.44 ± 0.26 | 95.57 ± 0.17 | 98.75 ± 0.22 |
| pp512 | - | - | 27.93 ± 0.07 | 52.47 ± 1.01 | 75.98 ± 0.15 | 97.20 ± 0.43 | 90.65 ± 5.70 |
| | | | | | | | |

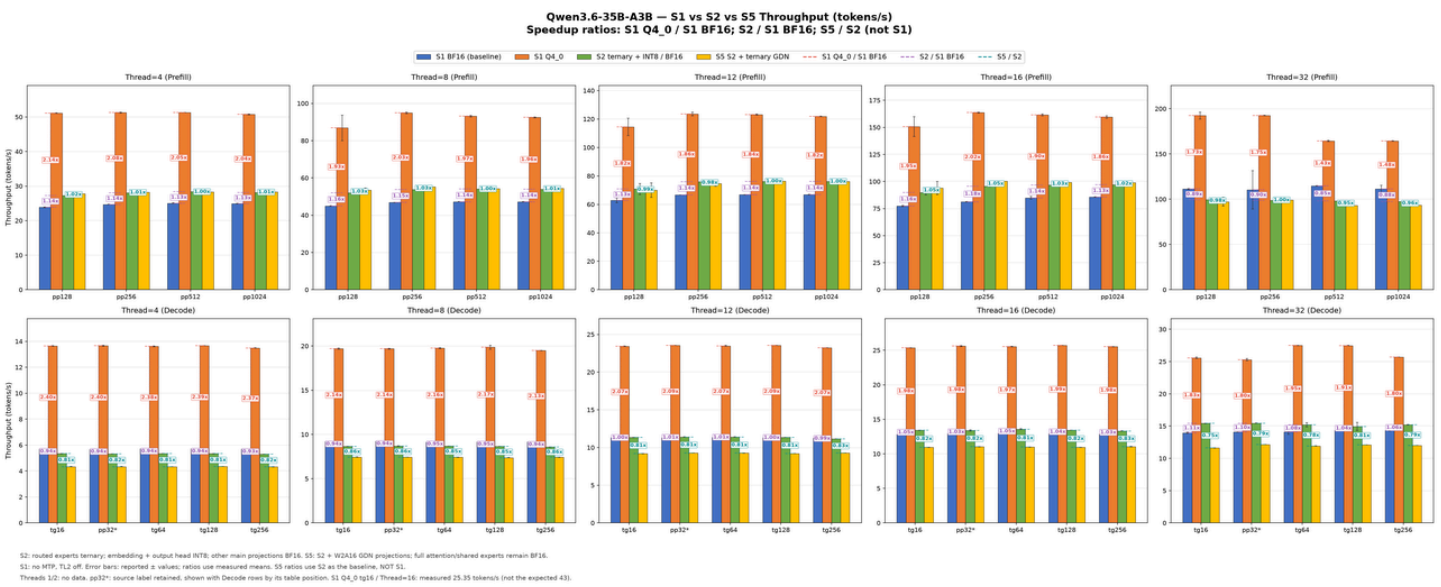
| | | | | | | | |
|---|---|---|---|---|---|---|---|
| pp1024 | - | - | 27.83 ± 0.09 | 53.20 ± 0.15 | 74.90 ± 0.02 | 96.42 ± 0.40 | 96.30 ± 0.40 |
| tg16 | - | - | 4.88 ± 0.01 | 7.88 ± 0.02 | 10.32 ± 0.01 | 12.12 ± 0.03 | 13.35 ± 0.09 |
| pp32 | - | - | 4.88 ± 0.01 | 7.92 ± 0.01 | 10.39 ± 0.04 | 11.99 ± 0.10 | 13.40 ± 0.01 |
| tg64 | - | - | 4.92 ± 0.00 | 7.91 ± 0.01 | 10.40 ± 0.01 | 12.15 ± 0.04 | 13.27 ± 0.01 |
| tg128 | - | - | 4.87 ± 0.02 | 7.93 ± 0.01 | 10.39 ± 0.00 | 12.29 ± 0.04 | 13.30 ± 0.06 |
| tg256 | - | - | 4.83 ± 0.01 | 7.83 ± 0.02 | 10.27 ± 0.02 | 12.04 ± 0.17 | 13.26 ± 0.02 |




## 7. S5: S2 基础上，再把 GDN 投影三值化

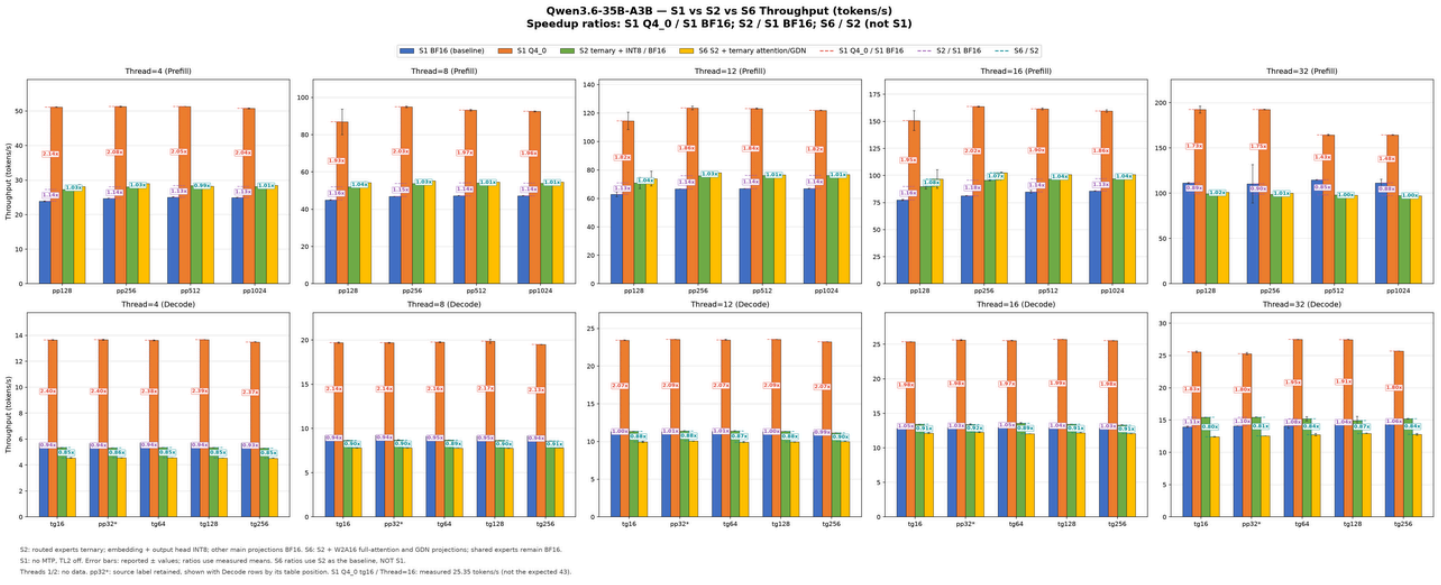
| Model ｜ Thread Number<br>Qwen3.6-35B-A3B | Thread = 1 （tokens / s） | Thread = 2 （tokens / s） | Thread = 4 （tokens / s） | Thread = 8 （tokens / s） | Thread = 12 （tokens / s） | Thread = 16 （tokens / s） | Thread = 32 （tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | 27.82 ± 0.04 | 53.47 ± 1.14 | 70.00 ± 5.12 | 94.05 ± 6.03 | 97.31 ± 4.75 |
| pp256 | - | - | | | | | |

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| | | | 28.27 ± 0.08 | 55.20 ± 0.16 | 74.58 ± 1.72 | 100.24 ± 0.10 | 99.27 ± 0.31 |
| pp512 | - | - | 28.30 ± 0.03 | 54.20 ± 0.12 | 76.42 ± 0.13 | 99.17 ± 0.11 | 93.07 ± 0.07 |
| pp1024 | - | - | 28.34 ± 0.14 | 54.42 ± 0.34 | 76.09 ± 0.22 | 98.90 ± 0.24 | 93.52 ± 0.13 |
| tg16 | - | - | 4.34 ± 0.01 | 7.44 ± 0.02 | 9.19 ± 0.02 | 10.94 ± 0.03 | 11.61 ± 0.01 |
| pp32 | - | - | 4.34 ± 0.01 | 7.44 ± 0.01 | 9.29 ± 0.01 | 11.03 ± 0.01 | 12.15 ± 0.01 |
| tg64 | - | - | 4.34 ± 0.00 | 7.42 ± 0.02 | 9.27 ± 0.01 | 10.98 ± 0.03 | 11.93 ± 0.01 |
| tg128 | - | - | 4.35 ± 0.00 | 7.38 ± 0.01 | 9.19 ± 0.00 | 10.95 ± 0.02 | 12.10 ± 0.01 |
| tg256 | - | - | 4.33 ± 0.01 | 7.42 ± 0.01 | 9.29 ± 0.00 | 11.04 ± 0.03 | 12.00 ± 0.01 |




## 8. S6: S2 基础上，full-attention和 GDN 投影都三值化

| Model \| Thread Number<br>Qwen3.6-35B-A3B | Thread = 1 （tokens / s） | Thread = 2 （tokens / s） | Thread = 4 （tokens / s） | Thread = 8 （tokens / s） | Thread = 12 （tokens / s） | Thread = 16 （tokens / s） | Thread = 32 （tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | 28.17 ± 0.50 | 54.24 ± 0.50 | 73.89 ± 5.18 | 96.68 ± 8.56 | 101.19 ± 1.26 |
| pp256 | - | - | 28.98 ± 0.23 | 55.21 ± 0.06 | 78.04 ± 0.26 | 102.63 ± 0.41 | 100.24 ± 0.19 |
| pp512 | - | - | 28.21 ± 0.11 | 54.58 ± 0.02 | 76.62 ± 0.06 | 100.95 ± 0.17 | 97.74 ± 0.45 |
| pp1024 | - | - | 28.50 ± 0.06 | 54.66 ± 0.37 | 76.84 ± 0.06 | 100.97 ± 0.06 | 97.04 ± 0.17 |
| tg16 | - | - | 4.55 ± 0.04 | 7.80 ± 0.02 | 9.95 ± 0.08 | 12.14 ± 0.06 | 12.41 ± 0.04 |
| pp32 | - | - | 4.56 ± 0.01 | 7.80 ± 0.02 | 10.07 ± 0.02 | 12.26 ± 0.03 | 12.57 ± 0.01 |
| tg64 | - | - | 4.56 ± 0.00 | 7.77 ± 0.01 | 9.93 ± 0.05 | 12.04 ± 0.01 | 12.75 ± 0.19 |
| tg128 | - | - | 4.55 ± 0.00 | 7.76 ± 0.01 | 9.94 ± 0.02 | 12.18 ± 0.03 | 12.95 ± 0.04 |
| tg256 | - | - | 4.52 ± 0.01 | 7.81 ± 0.00 | 10.01 ± 0.01 | 12.07 ± 0.01 | 12.79 ± 0.13 |



## 9. S7: S6 基础上，再把共享专家投影三值化

| Model \| Thread Number<br>Qwen3.6-35B-A3B | Thread = 1<br>（tokens / s） | Thread = 2<br>（tokens / s） | Thread = 4<br>（tokens / s） | Thread = 8<br>（tokens / s） | Thread = 12<br>（tokens / s） | Thread = 16<br>（tokens / s） | Thread = 32<br>（tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | | | | | |
| pp256 | - | - | | | | | |
| pp512 | - | - | | | | | |
| pp1024 | - | - | | | | | |
| tg16 | - | - | | | | | |
| pp32 | - | - | | | | | |
| tg64 | - | - | | | | | |
| tg128 | - | - | | | | | |
| tg256 | - | - | | | | | |

## 10. S8: 从 S2 出发，把其余大Linear改成 FP8

| Model \| Thread Number<br>Qwen3.6-35B-A3B | Thread = 1<br>（tokens / s） | Thread = 2<br>（tokens / s） | Thread = 4<br>（tokens / s） | Thread = 8<br>（tokens / s） | Thread = 12<br>（tokens / s） | Thread = 16<br>（tokens / s） | Thread = 32<br>（tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | | | | | |
| pp256 | - | - | | | | | |
| pp512 | - | - | | | | | |
| pp1024 | - | - | | | | | |
| tg16 | - | - | | | | | |
| pp32 | - | - | | | | | |

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| tg64 | - | - | | | | | |
| tg128 | - | - | | | | | |
| tg256 | - | - | | | | | |

## 11. S9: 从 S2 出发，把其余大Linear改成 INT8

| Model \| Thread Number<br>Qwen3.6-35B-A3B | Thread = 1<br>（tokens / s） | Thread = 2<br>（tokens / s） | Thread = 4<br>（tokens / s） | Thread = 8<br>（tokens / s） | Thread = 12<br>（tokens / s） | Thread = 16<br>（tokens / s） | Thread = 32<br>（tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | | | | | |
| pp256 | - | - | | | | | |
| pp512 | - | - | | | | | |
| pp1024 | - | - | | | | | |
| tg16 | - | - | | | | | |
| pp32 | - | - | | | | | |
| tg64 | - | - | | | | | |
| tg128 | - | - | | | | | |
| tg256 | - | - | | | | | |

## 12. Q4_0与Expert BitNet量化

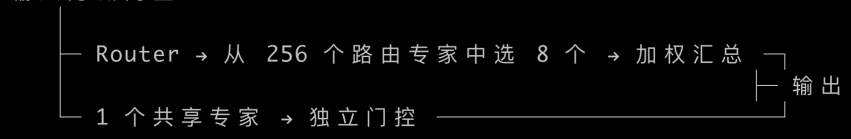
模型结构：30 层 Gated DeltaNet + 10 层全注意力，然后是MoE，其中expert权重占约 93%，但每个 token 每层只用 8/256，按实际参与计算的线性权重粗算，S2 的读取量降幅对应约 1.62倍的理想带宽收益，而不是文件压缩带来的约 5.6倍。




图中省略了每层的归一化和残差连接。具体为：

| 结构 | 本地模型配置 | 作用 |
| --- | --- | --- |
| GDN: Gated DeltaNet | 30 层，配置中叫 linear_attention | 通过门控和递归状态更新，处理序列信息 |
| Full Attention | 10 层；16 个 Q 头、2 个 KV 头 | 使用带输出门控的全注意力处理上下文 |
| MoE | 每一层都有，共 40 个 MoE 模块 | 对每个 token 做专家选择与特征变换 |
| Token Embedding | [248320, 2048] | 将 token ID 转换成隐藏向量 |
| LM Head | [248320, 2048]，不与 Embedding 共享权重 | 将隐藏向量映射到词表分数 |

每个 MoE 内部：路由专家 + 共享专家




- 路由专家（Routed experts）：每个 token、每一层选择其中 8 个。
- 共享专家（Shared expert）：所有 token 都经过，但输出受门控调节。
- 专家的中间维度都是 512，主干隐藏维度为 2048。

因此，Shared expert 不是与 GDN、Full Attention 并列的第三种注意力，而是每层 MoE 内部的一部分。

35B-A3B 表示约 350 亿总参数、每 token 约 30 亿激活参数，不代表只需要存储 30 亿参数。

按本地文本主干权重统计：

| 模型中的部分 | 原始 BF16 大小 | 在表格中的位置 |
|---|---|---|
| 路由专家 | 60.0000 GiB | 没有单列出来；S2 开始就已经三值量化 |
| 共享专家的三个投影 | 0.2344 GiB | Shared expert 投影 列 |
| 10 层全注意力的投影 | 0.5078 GiB | Full-attention 投影 列 |
| 30 层 GDN 的投影 | 1.8823 GiB | GDN 投影 列 |
| Embedding + LM Head | 1.8945 GiB | 没有单列出来；S2 开始使用 INT8 |
| Router、Norm、卷积等其余权重 | 0.0414 GiB | 大部分保留原精度，少数按规范提升精度 |
| 合计 | 64.5604 GiB | 正是 S1 |

最关键的一点：路由专家占了原始文本权重约 93%。
所以 S1 → S2 从 64.56 GiB 降到 11.60 GiB，主要是量化路由专家的结果；表格展示的三列，是在这个基础上继续研究的部分。

| 方案 | 要做的事情 | |
|---|---|---|
| S1 * | 官方原始 BF16，不量化，作为基准 | |
| S2 ** | Expert三值量化，Embedding 和输出头 INT8；其余主投影保持 BF16 | |
| S3 | S2 基础上，再把共享专家投影三值化 | |
| S4 | S2 基础上，再把full-attention投影三值化 | |
| S5 * | S2 基础上，再把 GDN 投影三值化 | |
| S6 * | S2 基础上，full-attention和 GDN 投影都三值化 | |
| S7 | S6 基础上，再把共享专家投影三值化 | |
| S8 ** | 从 S2 出发，把其余大Linear改成 FP8 | |
| S9 ** | 从 S2 出发，把其余大Linear改成 INT8 | |

| 表格列 | 对应的投影名称 |
|---|---|
| Shared expert | mlp.shared_expert.{gate_proj, up_proj, down_proj} |
| Full-attention | self_attn.{q_proj, k_proj, v_proj, o_proj} |
| GDN | linear_attn.{in_proj_qkv, in_proj_z, in_proj_a, in_proj_b, out_proj} |

这里有几个容易混淆的边界：

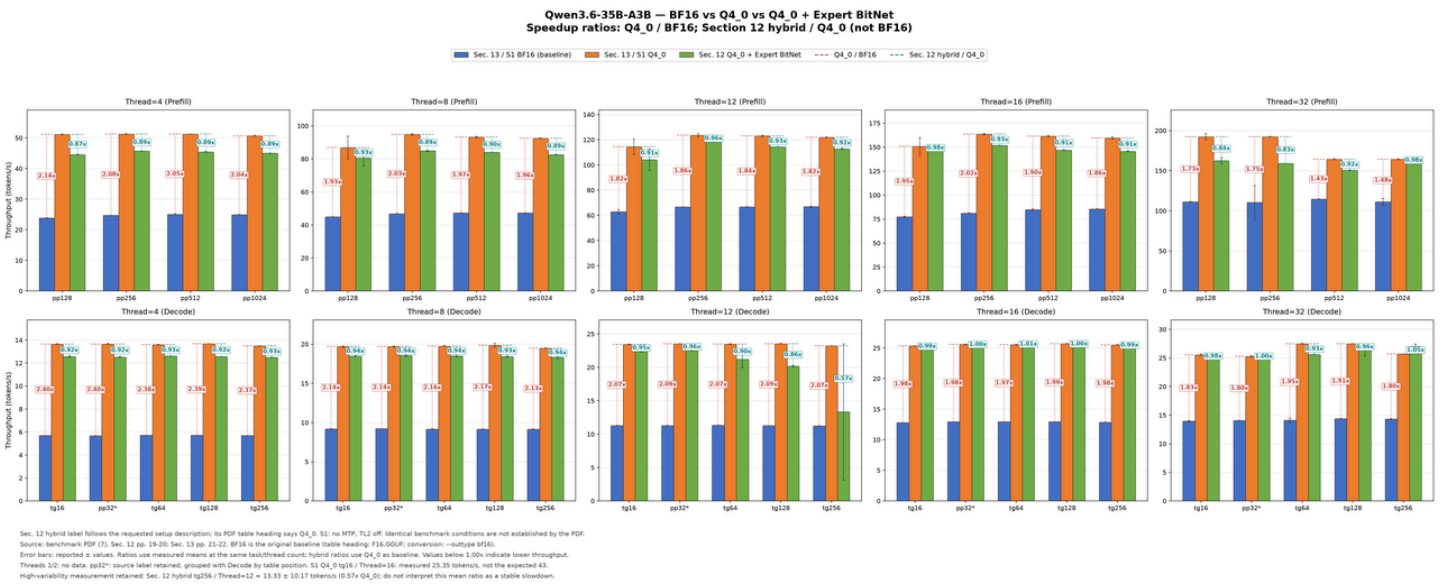
- GDN 包含 **a、b 两个门控投影**，不只是 qkv、z、out。
- Full-attention 的 q_proj **包含输出门控对应的行**。
- shared_expert.gate_proj 属于共享专家内部投影，在量化范围内。
- 但 Router 的 mlp.gate、独立的 shared_expert_gate **不在这三列新增量化的范围内**。

Q4_0

| 模型部分 | 默认 Q4_0 方案 | 当前 S2 方案 | Q4_0 方案下权重体积 |
|---|---|---|---|
| 40 层路由专家的 gate/up/down | **Q4_0** | 三值 packed-2，另存 BF16 scale | 16.8750 GiB |
| 40 层共享专家的 gate/up/down | **Q4_0** | BF16 | 0.0659 GiB |
| 10 层 Full Attention 的 q/k/v/o | **Q4_0** | BF16 | 0.1428 GiB |
| 30 层 GDN 的 qkv/z/a/b/out 投影 | **Q4_0** | BF16 | 0.5294 GiB |
| Token Embedding | **Q4_0** | INT8，另存 BF16 scale | 0.2664 GiB |
| LM Head | **Q6_K，不是 Q4_0** | INT8，另存 BF16 scale | 0.3885 GiB |
| Router、独立共享专家门控、Norm、卷积、其他小张量 | 继承输入 GGUF 的 **F32** | 大部分 BF16，少数 F32 | 0.0828 GiB |
| **合计** | 混合格式 | 混合格式 | **约 18.3508 GiB** |

| Model \| Thread Number<br>Qwen3.6-35B-A3B | Thread = 1 (tokens / s) | Thread = 2 (tokens / s) | Thread = 4 (tokens / s) | Thread = 8 (tokens / s) | Thread = 12 (tokens / s) | Thread = 16 (tokens / s) | Thread = 32 (tokens / s) |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | 44.55 ± 0.17 | 80.55 ± 4.92 | 104.14 ± 8.30 | 147.56 ± 0.37 | 162.53 ± 3.65 |
| pp256 | - | - | 45.66 ± 0.05 | 84.89 ± 0.28 | 118.26 ± 0.22 | 151.73 ± 0.19 | 159.10 ± 0.17 |

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| pp512 | - | - | 45.44 ± 0.13 | 83.92 ± 0.0 | 114.31 ± 0.07 | 146.78 ± 0.27 | 150.48 ± 0.34 |
| pp1024 | - | - | 45.00 ± 0.05 | 82.56 ± 0.25 | 112.72 ± 0.42 | 145.63 ± 0.42 | 161.75 ± 0.13 |
| tg16 | - | - | 12.56 ± 0.06 | 18.47 ± 0.06 | 22.36 ± 0.09 | 25.16 ± 0.13 | 25.01 ± 0.03 |
| pp32 | - | - | 12.52 ± 0.03 | 18.52 ± 0.08 | 22.55 ± 0.07 | 25.52 ± 0.02 | 25.24 ± 0.03 |
| tg64 | - | - | 12.60 ± 0.01 | 18.49 ± 0.06 | 21.19 ± 1.25 | 25.72 ± 0.02 | 25.62 ± 0.02 |
| tg128 | - | - | 12.56 ± 0.01 | 18.43 ± 0.12 | 20.18 ± 0.14 | 25.61 ± 0.01 | 26.33 ± 0.98 |
| tg256 | - | - | 12.48 ± 0.02 | 18.29 ± 0.11 | 13.33 ± 10.17 | 25.39 ± 0.02 | 27.01 ± 0.43 |




## 13. S1: Qwen3.6-35B-A3B-BF16 官方原始 BF16，不量化，作为基准

65G Qwen3.6-35B-A3B-bf16.gguf

代码块

```
## 测试的时候不加MTP
python3 convert_hf_to_gguf.py \
  /data3/huangxin/model_list/Qwen3.6-35B-A3B \
  --outfile /data3/huangxin/model_list/Qwen3.6-35B-A3B/Qwen3.6-35B-A3B-bf16.gguf \
  --outtype bf16 \
```

```
6     --no-mtp
```

- 不开启TL2
  - F16.GGUF

| Model \| Thread Number<br>Qwen3.6-35B-A3B | Thread = 1<br>（tokens / s） | Thread = 2<br>（tokens / s） | Thread = 4<br>（tokens / s） | Thread = 8<br>（tokens / s） | Thread = 12<br>（tokens / s） | Thread = 16<br>（tokens / s） | Thread = 32<br>（tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | 23.87 ± 0.11 | 44.93 ± 0.10 | 62.88 ± 1.72 | 77.38 ± 0.67 | 111.29 ± 0.41 |
| pp256 | - | - | 24.70 ± 0.02 | 46.82 ± 0.04 | 66.63 ± 0.06 | 81.22 ± 0.28 | 110.33 ± 21.24 |
| pp512 | - | - | 25.06 ± 0.12 | 47.24 ± 0.12 | 66.79 ± 0.14 | 84.89 ± 1.27 | 114.64 ± 0.35 |
| pp1024 | - | - | 24.92 ± 0.06 | 47.22 ± 0.12 | 66.85 ± 0.30 | 85.63 ± 0.24 | 111.32 ± 4.18 |
| tg16 | - | - | 5.69 ± 0.01 | 9.19 ± 0.03 | 11.30 ± 0.02 | 12.82 ± 0.01 | 13.95 ± 0.09 |
| pp32 | - | - | 5.68 ± 0.01 | 9.22 ± 0.03 | 11.29 ± 0.02 | 12.95 ± 0.01 | 14.07 ± 0.03 |
| tg64 | - | - | 5.71 ± 0.02 | 9.14 ± 0.08 | 11.33 ± 0.02 | 12.95 ± 0.01 | 14.10 ± 0.40 |
| tg128 | - | - | 5.71 ± 0.00 | 9.15 ± 0.03 | 11.29 ± 0.00 | 12.95 ± 0.01 | 14.38 ± 0.03 |
| tg256 | - | - | 5.69 ± 0.01 | 9.15 ± 0.04 | 11.25 ± 0.01 | 12.88 ± 0.02 | 14.31 ± 0.08 |

代码块

```
1  ## 测试的时候不加MTP
2  /home/huangxin/code_list/bitnet-moe-
   script/build_script/build_bin_upstream/bin/llama-quantize \
3     /data3/huangxin/model_list/Qwen3.6-35B-A3B/Qwen3.6-35B-A3B-bf16.gguf \
4     /data3/huangxin/model_list/Qwen3.6-35B-A3B/Qwen3.6-35B-A3B-Q4_0.gguf \
```

```
5       Q4_0
```

- Q4_0.GGUF

| Model \| Thread Number<br>Qwen3.6-35B-A3B | Thread = 1<br>（tokens / s） | Thread = 2<br>（tokens / s） | Thread = 4<br>（tokens / s） | Thread = 8<br>（tokens / s） | Thread = 12<br>（tokens / s） | Thread = 16<br>（tokens / s） | Thread = 32<br>（tokens / s） |
|---|---|---|---|---|---|---|---|
| pp128 | - | - | 51.15 ± 0.09 | 86.85 ± 6.89 | 114.46 ± 6.17 | 150.83 ± 9.19 | 192.39 ± 3.91 |
| pp256 | - | - | 51.30 ± 0.13 | 94.88 ± 0.47 | 123.62 ± 1.27 | 163.67 ± 0.50 | 192.56 ± 0.37 |
| pp512 | - | - | 51.30 ± 0.01 | 93.18 ± 0.40 | 123.15 ± 0.41 | 161.54 ± 0.74 | 164.45 ± 0.68 |
| pp1024 | - | - | 50.74 ± 0.16 | 92.51 ± 0.24 | 121.88 ± 0.19 | 159.61 ± 1.20 | 164.29 ± 0.36 |
| tg16 | - | - | 13.65 ± 0.02 | 19.70 ± 0.08 | 23.44 ± 0.04 | 25.35 ± 0.01<br>(预期应43toks/s) | 25.57 ± 0.12 |
| pp32 | - | - | 13.66 ± 0.04 | 19.70 ± 0.05 | 23.55 ± 0.01 | 25.61 ± 0.06 | 25.30 ± 0.17 |
| tg64 | - | - | 13.61 ± 0.03 | 19.76 ± 0.06 | 23.49 ± 0.05 | 25.54 ± 0.05 | 27.49 ± 0.04 |
| tg128 | - | - | 13.67 ± 0.0 | 19.86 ± 0.23 | 23.56 ± 0.01 | 25.71 ± 0.02 | 27.48 ± 0.01 |
| tg256 | - | - | 13.49 ± 0.01 | 19.49 ± 0.02 | 23.24 ± 0.0 | 25.52 ± 0.02 | 25.70 ± 0.01 |